

Informe del análisis exploratorio

Dataset: Financial PhraseBank · TFM Roboadvisor personalizado — Módulo M1

Fase del TFM	Fase 1 · EDA y exploración de datasets NLP (semanas 3–4)
Dataset	Financial PhraseBank (Malo et al., 2014)
Versión	14.780 filas × 3 columnas · 4.838 frases únicas
Objetivo	Validar el dataset como gold standard para evaluar FinBERT zero-shot en M1

1. Contexto y alcance del análisis

El Financial PhraseBank es el dataset de referencia para análisis de sentimiento financiero en inglés. Consiste en frases extraídas de prensa financiera y notas de prensa del mercado OMX Helsinki (~2008–2013), anotadas manualmente por 16 anotadores especializados con una de tres etiquetas —**positive**, **neutral** o **negative**— desde la perspectiva de un inversor.

FinBERT (ProsusAI/finbert), el modelo que utiliza el **Módulo M1** del TFM, fue pre-entrenado precisamente sobre este corpus. Por tanto, el dataset no se usa como conjunto de entrenamiento —sería *data leakage* puro— sino como **test set de referencia** para reportar la accuracy de FinBERT en su dominio nativo y establecer una cota superior realista de lo que cabe esperar sobre las 30 personas sintéticas del TFM.

El análisis exploratorio de este informe no es un EDA genérico: está orientado a responder cinco preguntas operativas que condicionan el diseño de M1.

#	Pregunta operativa
Q1	¿Qué subconjunto del dataset usar como <i>gold standard</i> para evaluar FinBERT?
Q2	¿Qué desbalance de clases hay que asumir y cómo afecta a la métrica de éxito?
Q3	¿Hay fugas de información (duplicados entre niveles de agreement) que contaminen la evaluación?
Q4	¿Las longitudes de frase son compatibles con el límite de 512 tokens de FinBERT?
Q5	¿Qué baseline realista de accuracy debe batir el sistema NLP dual?

El análisis se estructura en cinco fases. Las fases de carga y resumen general se han omitido de este informe porque no aportan conclusiones sustantivas: el dataset pesa menos de 5 MB, se carga sin incidencias y no tiene nulos.

2. Fase A · Calidad de datos

El primer chequeo busca nulos, duplicados y cualquier patología estructural que pudiera sesgar todos los análisis posteriores. Es la fase más crítica del informe porque aquí se destapa un hallazgo con implicaciones directas sobre el diseño experimental de M1.

2.1 · Nulos y duplicados exactos

No hay valores nulos en ninguna columna. Se detectan 22 filas exactamente duplicadas (0,15% del total), ruido residual del proceso de concatenación que se elimina con `drop_duplicates` sin coste analítico.

2.2 · Hallazgo crítico: estructura anidada por nivel de agreement

Hallazgo crítico para M1

El CSV contiene **14.780 filas pero únicamente 4.838 frases únicas**. Cada frase aparece, en promedio, 3,05 veces. La causa es que el Financial PhraseBank se publica originalmente en cuatro ficheros anidados (*Sentences_50Agree*, *66Agree*, *75Agree*, *AllAgree*) donde cada uno contiene un subconjunto estricto del anterior. Se ha verificado empíricamente la inclusión: **allagree** $\subset$ **75agree** $\subset$ **66agree** $\subset$ **50agree**. Si se evalúa FinBERT sobre el CSV sin deduplicar, la misma frase se cuenta hasta cuatro veces y la accuracy reportada queda inflada artificialmente.

Nivel de agreement	Frases únicas	¿Subconjunto del anterior?
50agree	4.838	—
66agree	4.211	Sí ($\subset$ 50agree)
75agree	3.448	Sí ($\subset$ 66agree)
allagree	2.259	Sí ($\subset$ 75agree)

Adicionalmente, solo **2 frases** presentan etiquetas inconsistentes entre niveles —casos borderline que cambiaron de clase al subir el umbral de consenso—. Se resuelven conservando la etiqueta del nivel de mayor agreement disponible.

Conclusión de la fase

La unidad de análisis debe ser **la frase única**, no la fila del CSV. Se trabaja con un DataFrame deduplicado de 4.838 frases. Este hecho debe declararse explícitamente en la memoria del TFM; de lo contrario, cualquier métrica de evaluación de M1 estaría sobrestimada en un factor de $\sim 3\times$.

3. Fase B · Análisis univariado

Caracterización individual de las tres variables: la etiqueta de sentimiento, el nivel de agreement y la longitud de las frases. El objetivo es dimensionar el dataset de trabajo y detectar restricciones técnicas para FinBERT.

3.1 · Distribución de la variable objetivo

Sobre el dataset deduplicado (4.838 frases), la distribución de clases es:

Clase	Frecuencia	Proporción
neutral	2.879	≈ 59,5%
positive	1.363	≈ 28,2%
negative	596	≈ 12,3%

El desbalance es notable pero **refleja la distribución real** de tonos en prensa financiera: dominan las notas informativas (neutrales), las noticias positivas son frecuentes y las negativas —aunque mediáticamente visibles— son minoritarias en términos absolutos. No se trata de un artefacto del muestreo.

3.2 · Niveles de agreement y tamaño del subset de evaluación

El tamaño disponible depende del umbral de consenso que se exija:

Umbral exigido	Nº de frases	Uso recomendado
≥ 50% (todo)	4.838	Análisis cualitativo de errores; no usar como gold
≥ 66%	4.211	Uso secundario; más datos con algo más de ruido
≥ 75%	3.448	Segunda métrica de control (robustez)
= 100% (allagree)	2.259	Gold standard por defecto — etiquetas de máxima fiabilidad

3.3 · Longitud de las frases

Se calculan dos medidas: caracteres y palabras. Las distribuciones presentan sesgo derecho clásico de corpus textuales (mediana < media). La frase más larga tiene 315 caracteres y 81 palabras.

Métrica	Mediana	Media	Máximo	Límite de FinBERT
Caracteres	117	126	315	≈ 2.000 (equiv. 512 tokens)
Palabras	21	23	81	—

Conclusión de la fase

Todas las frases caben holgadamente en los 512 tokens del tokenizer de FinBERT. **No se requiere estrategia de truncado ni chunking**. El desbalance de clases obliga a complementar la accuracy con **F1-macro** y matriz de confusión: predecir siempre *neutral* ya acierta el 60%, por lo que la accuracy aislada es engañosa. Como **gold standard** se selecciona el subconjunto **allagree (n = 2.259)**, con reporte complementario sobre **≥75agree (n = 3.448)** para demostrar robustez.

4. Fase C · Análisis bivariado

Se examinan tres relaciones entre variables para entender si existen patrones que condicionen la evaluación de FinBERT.

4.1 · Clase × nivel de agreement

La proporción de cada clase se mantiene estable a través de los cuatro niveles de agreement: *neutral* oscila entre 59% y 62%, *positive* entre 25% y 28%, *negative* entre 12% y 13%. No hay clases 'fáciles de consensuar' ni 'polémicas' de forma significativa en la práctica.

4.2 · Longitud × clase

Las frases **neutrales son, en mediana, ligeramente más largas** (22 palabras) que las positivas o negativas (20 palabras). Interpretación: la neutralidad suele requerir más contexto descriptivo —cifras, comparativas, explicaciones— mientras que lo positivo o negativo se condensa en expresiones valorativas más cortas. La diferencia es estadísticamente significativa pero de magnitud pequeña (ver Fase E).

4.3 · Vocabulario distintivo por clase

El análisis cualitativo del vocabulario más frecuente por clase (excluyendo stopwords) revela con claridad la señal léxica que FinBERT aprovecha:

Clase	Vocabulario característico
negative	<i>fell, decreased, loss, lower, down, declined</i>
neutral	<i>company, quarter, million, eur, share, year</i>
positive	<i>increased, rose, grew, profit, higher, up, growth</i>

La separabilidad léxica es notable: los verbos de movimiento direccional (*rose/fell, increased/decreased*) son el marcador más claro, y las clases neutrales están dominadas por sustantivos de contexto sin carga emocional.

Conclusión de la fase

El desbalance de clases es **estable entre niveles de agreement**, por lo que la elección del subset no introduce sesgos de composición. El vocabulario distintivo por clase es claramente separable mediante señales léxicas habituales del lenguaje financiero: esta es precisamente la señal para la que FinBERT fue pre-entrenado, lo que justifica la expectativa de buen rendimiento en modo zero-shot.

5. Fase D · Detección de frases atípicas

En un corpus textual no tiene sentido buscar outliers 'numéricos' como en datos tabulares clásicos. Sin embargo, sí es útil identificar frases **estructuralmente atípicas** —muy largas, con alta densidad numérica, con patrones de mayúsculas extremos— porque podrían ensuciar la accuracy agregada del modelo si se concentran los errores en ellas.

Se aplican tres métodos complementarios sobre cuatro features: longitud en caracteres, longitud en palabras, ratio de dígitos y ratio de mayúsculas.

Método	Criterio	Aplicable
IQR (Tukey)	Fuera de $[Q1 - 1,5 \cdot IQR, Q3 + 1,5 \cdot IQR]$ sobre <code>len_words</code>	Univariado · robusto
Z-score	$ z > 3$ sobre <code>len_words</code>	Univariado · supone normalidad
Isolation Forest	Anomalía multivariante sobre las 4 features (<code>random_state = 42</code>)	Multivariado

Aviso metodológico: dado que la distribución de longitud no es normal (cola derecha pronunciada), el criterio z-score subestima el número de outliers frente a IQR. Por eso se reportan ambos conjuntamente.

El examen cualitativo de las frases marcadas por Isolation Forest revela un patrón nítido: en su mayoría son **listas de cifras trimestrales** o enumeraciones muy largas con alta densidad numérica (ingresos por segmento, resultados por país, etc.). Son frases perfectamente válidas pero estructuralmente distintas del resto del corpus.

Conclusión de la fase

Las frases atípicas **no se eliminan** del dataset. Se marcan mediante un flag booleano (`is_outlier_iso`) que permitirá, en la Fase 2 del TFM, analizar la accuracy de FinBERT **condicionada** a este grupo. La hipótesis razonable a contrastar en M1 es que FinBERT degrada su rendimiento en frases con mucho ruido numérico y poca señal léxica, y esto sería un hallazgo reportable en la memoria.

6. Fase E · Tests de hipótesis

Cuatro contrastes con $\alpha = 0,05$ para formalizar estadísticamente las intuiciones visuales anteriores y dar soporte cuantitativo a las decisiones de diseño de M1.

Test	Hipótesis nula	Resultado	Interpretación
D'Agostino K^2	len_words sigue distribución Normal	$p \approx 0$ · Rechazo H_0	La longitud no es normal. Obliga a usar tests no paramétricos en el resto del análisis.
Chi ² de Pearson	label y agreement_level son independientes	$p < 0,05$ pero Cramér's V < 0,1	Hay asociación estadística pero el tamaño del efecto es trivial: sin relevancia operativa.
Kruskal-Wallis	Las tres clases tienen la misma distribución de longitud	$p \approx 0$ · Rechazo H_0	<i>Neutral</i> es significativamente más larga que <i>positive</i> y <i>negative</i> .
Spearman ρ	len_words y agreement_level no correlacionan	$\rho \approx -0,06$ · $p < 0,05$	Correlación significativa por tamaño muestral pero prácticamente nula.

Conclusión de la fase

Los tests formalizan lo observado visualmente. Dos consideraciones metodológicas importantes para la memoria: (1) sobre $n \approx 4.800$ observaciones, **cualquier asociación no nula se detecta como significativa**, por lo que el tamaño del efecto (Cramér's V, ρ) es la medida relevante, no el p-valor aislado; (2) las asociaciones detectadas (label $\times$ agreement, longitud $\times$ agreement) tienen **magnitud trivial**, lo que refuerza la decisión de usar *allagree* sin preocupación por sesgos sistemáticos respecto al CSV completo.

7. Conclusiones globales sobre el dataset

7.1 · Caracterización resumida

- El Financial PhraseBank es un corpus **pequeño pero limpio**: ~4.800 frases únicas, sin nulos, con etiquetas de calidad y longitudes uniformes.
- Su estructura distribuida en cuatro niveles de agreement es una característica metodológica explícita del dataset original, **no un defecto del CSV**, pero obliga a deduplicar antes de cualquier evaluación.
- El desbalance de clases (60/28/12) refleja la distribución real del lenguaje financiero periodístico y debe asumirse tal cual, no corregirse.
- La separabilidad léxica entre clases es alta y compatible con el tipo de señal que capturan los modelos BERT financieros.

7.2 · Fortalezas del dataset para el TFM

- Es el **dataset canónico** en el dominio: los resultados son directamente comparables con la literatura (Araci 2019, Yang et al. 2020).
- Las etiquetas de *allagree* tienen fiabilidad máxima por construcción (consenso del 100% entre anotadores financieros expertos).
- Tamaño adecuado para evaluación robusta sin entrenamiento: 2.259 frases suponen intervalos de confianza suficientemente estrechos para una accuracy reportable.
- Compatibilidad total con el tokenizer de FinBERT (ninguna frase requiere truncado).

7.3 · Limitaciones que deben declararse en la memoria

- **Desfase de dominio**: prensa financiera B2B vs. respuestas emocionales B2C. La accuracy que FinBERT alcance sobre el Financial PhraseBank es una **cota superior** de su rendimiento sobre las respuestas traducidas de los inversores sintéticos del TFM.
- **Desfase temporal**: el corpus cubre aproximadamente 2008–2013, sin incluir vocabulario fintech, cripto ni pandemias. Impacto bajo para la tarea de sentimiento (señal lingüística, no fáctica) pero mencionable.
- **Sesgo geográfico**: mercado nórdico (OMX Helsinki). El léxico específico (nombres de empresas, mercancías nórdicas) es minoritario pero existe.
- **Idioma inglés nativo**: el pipeline del TFM introducirá ruido adicional por traducción automática ES→EN. Es precisamente la justificación del **Pipeline B dual** (pysentimiento en español nativo) como control.

7.4 · Decisiones operativas para el Módulo M1

Decisión	Valor
Subset para accuracy principal	allagree (n = 2.259)
Subset para robustez	≥ 75agree (n = 3.448)
Métrica primaria	Accuracy global
Métricas complementarias	F1-macro + matriz de confusión
Baseline naive a batir	~60% (clase mayoritaria <i>neutral</i>)
Umbral esperado (Araci 2019)	~85–86% de accuracy zero-shot sobre allagree
Fine-tuning	No se aplica — queda fuera de alcance (ver Fase 0)
Imputación / scaling	No aplica — entrada directa al tokenizer

Con estas decisiones, el dataset queda caracterizado, dimensionado y operativamente listo para su uso en la Fase 2 del TFM (implementación completa del Módulo M1: cuestionario MiFID II + NLP dual FinBERT / pysentimiento + reglas de fusión + validación sobre personas sintéticas).

Referencias. Malo, P., Sinha, A., Korhonen, P., Wallenius, J. & Takala, P. (2014). Good Debt or Bad Debt: Detecting Semantic Orientations in Economic Texts. *JASIST*, 65(4), 782–796. · Araci, D. (2019). FinBERT: Financial Sentiment Analysis with Pre-trained Language Models. *arXiv:1908.10063*. · Pérez, J. M. et al. (2021). pysentimiento: A Python Toolkit for Sentiment Analysis. *arXiv:2106.09462*.