

Trabajo Fin de Máster

# Fase 1: Análisis Exploratorio de Datos

TFM — Roboadvisor Personalizado para el Inversor Retail

---

Autor

Directora/Director

Fecha 12 de mayo de 2026

Versión 1.0

## 1. Introducción y Objetivos de la Fase

El presente documento describe el análisis exploratorio de datos (EDA) correspondiente a la Fase 1 del Trabajo Fin de Máster titulado *Roboadvisor Personalizado para el Inversor Retail*. Esta fase constituye la base empírica sobre la que se asientan los módulos de modelización posteriores, proporcionando validación de las hipótesis de datos antes de cualquier proceso de entrenamiento o inferencia.

### Posición en la arquitectura de cinco módulos (M1→M5):

El proyecto se organiza en cinco módulos con flujo de datos unidireccional: M1 (Perfilado NLP), M2 (Universo de activos), M3 (Optimización de carteras), M4 (Backtesting y validación) y M5 (Demo Streamlit, opcional). La Fase 1 es previa a todos ellos y actúa como *data quality gate*: ningún módulo puede avanzar sin que los datos que consume estén caracterizados, limpios y documentados. El EDA precede a la modelización porque permite detectar problemas de calidad, validar supuestos de distribución e informar decisiones de diseño antes de invertir coste computacional en entrenamientos o descargas masivas de datos de mercado.

### Las tres subtareas de la Fase 1 son:

| Subtarea                   | Descripción                                                                                               | Criterio Go/No-Go                               |
|----------------------------|-----------------------------------------------------------------------------------------------------------|-------------------------------------------------|
| 1A — Financial PhraseBank  | EDA del dataset de sentimiento financiero para validar el dataset de acuerdo a $\text{F1-score} \geq 0.8$ | Balance de acuerdo a $\text{F1-score} \geq 0.8$ |
| 1B — ETFs UCITS            | Selección y análisis del universo de 9 ETFs UCITS históricos de 2010-2021                                 | Verificación de perfil por perfil, o            |
| 1C — Cuestionario MiFID II | Diseño del cuestionario y generación de 30 personas sintéticas para validar a 30 personas                 | Cuestionario finalizado a 30 personas con 100%  |

## 2. Fase 1A — EDA del Financial PhraseBank

### 2.1 Descripción del Dataset

El Financial PhraseBank (Malo et al., 2014) es el *corpus* de referencia para análisis de sentimiento financiero en inglés. Comprende frases extraídas de noticias financieras y notas de prensa del mercado OMX Helsinki, correspondientes al período aproximado 2008–2013. Fue anotado manualmente por 16 anotadores expertos (estudiantes y profesores de finanzas) con una de tres etiquetas de sentimiento: **positive**, **neutral** o **negative**.

El dataset se distribuye originalmente en cuatro ficheros de texto plano según el umbral de acuerdo entre anotadores: *Sentences\_50Agree.txt*, *Sentences\_66Agree.txt*, *Sentences\_75Agree.txt* y *Sentences\_AllAgree.txt*. En la versión CSV consolidada utilizada en este proyecto, la columna `agreement_level` codifica este umbral. El esquema resultante contiene tres columnas: `sentence`, `label` y `agreement_level`.

El fichero consolidado contiene **14.780 filas**, pero únicamente **4.838 frases únicas**. La discrepancia refleja la estructura anidada del corpus: cada frase aparece repetida en cada nivel de acuerdo en que fue incluida (cadena de inclusión:  $\text{allagree} \subset \text{75agree} \subset \text{66agree} \subset \text{50agree}$ ), lo que genera ~67% de duplicados entre filas. Este hallazgo es crítico para el diseño de M1: cualquier evaluación de modelo sobre el CSV sin deduplicación previa

produciría métricas artificialmente infladas.

## 2.2 Calidad de Datos

| Aspecto                                       | Resultado                       | Acción aplicada                                            |
|-----------------------------------------------|---------------------------------|------------------------------------------------------------|
| Nulos                                         | Sin nulos (0 en las 3 columnas) | Ninguna                                                    |
| Duplicados exactos (3 columnas)               | 22 filas (0.15%)                | Eliminados con <code>drop_duplicates()</code>              |
| Estructura anidada (misma frase en 2 niveles) | 9.412 frases (67.27%)           | Deduplicación por sentence: 14.780 → 4.838                 |
| Etiquetas inconsistentes entre 2 niveles      | 2 frases                        | Se conserva etiqueta del nivel de mayor consenso (máximo a |

La estructura anidada no constituye un error del CSV, sino la forma de distribución original de Malo et al. (2014). La deduplicación por sentence es obligatoria antes de cualquier evaluación de modelo. Las 2 frases con etiqueta inconsistente representan casos borderline en los que la etiqueta mayoritaria cambió al aumentar el umbral de consenso; se resuelven conservando la etiqueta del nivel con mayor acuerdo.

## 2.3 Análisis Univariado

### Distribución de la variable objetivo (clases de sentimiento):

Sobre el DataFrame deduplicado (4.838 frases únicas), la distribución de clases muestra un desbalance notable dominado por la clase *neutral*:

| Clase    | Frases únicas | Porcentaje (%) |
|----------|---------------|----------------|
| neutral  | 2.871         | 59,34          |
| positive | 1.363         | 28,17          |
| negative | 604           | 12,49          |
| TOTAL    | 4.838         | 100,00         |

Este desbalance tiene consecuencias directas para M1: (1) un clasificador trivial que prediga siempre *neutral* alcanza el **59,34% de accuracy** — éste es el baseline que FinBERT debe batir ampliamente; (2) la métrica de evaluación principal debe ser **F1-macro** (no accuracy), pues penaliza por igual los errores en las tres clases y no está sesgada por la dominancia de la clase mayoritaria.

### Distribución por nivel de agreement (sobre frases únicas):

| Nivel    | Frases únicas | ¿Subconjunto del anterior? |
|----------|---------------|----------------------------|
| 50agree  | 4.838         | —                          |
| 66agree  | 4.211         | Sí                         |
| 75agree  | 3.448         | Sí                         |
| allagree | 2.259         | Sí                         |

La cadena de inclusión confirma que  $\text{allagree} \subset 75\text{agree} \subset 66\text{agree} \subset 50\text{agree}$ . Las 2.259 frases del nivel *allagree* son el subconjunto de máxima fiabilidad de etiquetado y constituyen el *gold standard* para la validación de FinBERT en M1.

**Longitud de las frases (DataFrame deduplicado, n=4.838):**

| Estadístico | Longitud (caracteres) | Longitud (palabras) |
|-------------|-----------------------|---------------------|
| Media       | 128,06                | 23,09               |
| Mediana     | 119,00                | 21,00               |
| Desv. est.  | 56,41                 | 9,94                |
| Mínimo      | 9                     | 2                   |
| Máximo      | 315                   | 81                  |

El análisis de longitud revela que el 100% de las frases encaja dentro del límite de **512 tokens** del tokenizador de FinBERT (máximo de 315 caracteres ■ 512 tokens). No es necesaria ninguna estrategia de truncado ni de *chunking* para M1. Las distribuciones presentan sesgo positivo (cola derecha), con mediana < media, lo que motiva el uso de estadísticos no paramétricos en los tests de hipótesis.

**2.4 Análisis Bivariado y Tests Estadísticos**

Se realizaron cuatro tests formales con nivel de significación  $\alpha = 0.05$  para validar las relaciones observadas en el análisis exploratorio:

| Test                        | Hipótesis nula                 | Estadístico     | p-valor                    | Conclusión                          |
|-----------------------------|--------------------------------|-----------------|----------------------------|-------------------------------------|
| D'Agostino K <sup>2</sup>   | len_words ~ Normal             | 337,92          | 4,18×10 <sup>-10</sup> ■■■ | Rechazada: distribución no normal   |
| Chi <sup>2</sup> de Pearson | label ⊥ agreement_level        | 56,79 (df=6)    | < 0,0001                   | Rechazada: asociación existe        |
| Cramér's V                  | — (tamaño del efecto)          | V = 0,077       | —                          | Asociación trivial (V < 0,10)       |
| Kruskal-Wallis              | Longitud igual en las 3 clases | 65,14           | 7,15×10 <sup>-11</sup> ■■■ | Rechazada: diferencia significativa |
| Spearman                    | Longitud ⊥ agreement           | $\rho = -0,076$ | 1,39×10 <sup>-10</sup> ■■■ | Asociación mínima (efecto trivial)  |

**Interpretación metodológica crítica para M1:** el test Chi<sup>2</sup> detecta una asociación estadísticamente significativa entre la etiqueta de clase y el nivel de agreement, pero el **Cramér's V = 0,077** (muy por debajo del umbral V < 0,10 de asociación trivial) indica que dicha asociación es prácticamente irrelevante. La distribución de clases se mantiene estable a lo largo de todos los niveles de consenso (~60% neutral, ~25–36% positive, ~10–14% negative). **Conclusión para el diseño de M1:** no está justificado aplicar ponderaciones diferenciales por nivel de agreement en la evaluación de FinBERT; todos los niveles son comparables en composición de clases y el subconjunto allagree no presenta sesgo selectivo de clase.

**2.5 Subconjunto Gold para Validación de FinBERT**

Se recomienda el subconjunto **allagree** (n = 2.259 frases) como gold standard de evaluación de FinBERT por las siguientes razones: (1) cada etiqueta ha sido acordada por el 100% de los 16 anotadores, minimizando el ruido de etiquetado; (2) el tamaño es suficiente para estimaciones robustas de F1-macro con intervalos de confianza razonables; (3) la composición de clases es representativa del corpus completo.

**Umbral de éxito (Go/No-Go):**  $F1\text{-macro} \geq 0,85$  sobre *allagree*, alineado con los resultados reportados por Araci (2019) para FinBERT zero-shot en este mismo corpus. El baseline naive (clase mayoritaria: predecir siempre *neutral*) alcanza el **59,34% de accuracy**. FinBERT debe superar este umbral ampliamente para justificar el pipeline NLP frente a una regla heurística.

**Riesgo de domain shift:** el Financial PhraseBank cubre prensa financiera en inglés sobre empresas nórdicas (~2008–2013, mercado OMX Helsinki). El caso de uso de producción son respuestas en castellano de inversores retail traducidas automáticamente al inglés mediante Opus-MT. La degradación de rendimiento entre dominios es esperable y debe declararse como limitación en la memoria del TFM. El  $F1\text{-macro} \geq 0,85$  sobre este corpus es condición necesaria pero no suficiente para validar el pipeline completo.

## 2.6 Conclusiones y Decisiones para M1

1. El CSV debe deduplicarse por sentence antes de cualquier evaluación de modelo (14.780 → 4.838 frases únicas). Sin este paso, las métricas estarían artificialmente infladas.
2. El subconjunto *allagree* ( $n = 2.259$ ) es el gold standard recomendado por máxima fiabilidad de etiquetado y composición de clases representativa.
3. La métrica principal de evaluación es **F1-macro**; el umbral Go/No-Go es 0,85 (Araci, 2019). La accuracy aislada es engañosa dado el desbalance 60/28/12.
4. No es necesario ningún ajuste por nivel de agreement (Cramér's  $V = 0,077 < 0,10$ ): todos los niveles son comparables y no requieren ponderación diferencial.
5. No es necesaria ninguna estrategia de truncado para FinBERT:  $\max(\text{len\_chars}) = 315$  ■ 512 tokens.
6. El dominio del corpus (~2008–2013, OMX Helsinki, inglés) difiere del caso de uso (inversor retail, español traducido). El riesgo de domain shift debe declararse explícitamente en la memoria.

### 3. Fase 1B — EDA del Universo de ETFs UCITS

#### 3.1 Criterios de Selección

El universo de activos se construye sobre nueve ETFs UCITS que satisfacen los siguientes criterios de admisibilidad: (1) conformidad UCITS (diversificación reglamentada, admisibles para el inversor retail europeo); (2) denominación en EUR o cobertura EUR-hedged; (3) histórico de precios disponible desde 2010 (mínimo de 15 años para calibración estadística robusta); (4) AUM superior a 500 M EUR (proxy de liquidez); (5) gestoras iShares (BlackRock) e Invesco como filtro de liquidez y trazabilidad. El período de análisis efectivo, determinado por la fecha de inicio del ticker más tardío, es **2010-09-15** → **2026-05-01** (4.010 observaciones, ~15,91 años).

La asignación de cada ETF a un perfil de riesgo sigue una lógica basada en la clase de activo subyacente: renta fija → Conservador, renta fija de alta rentabilidad / infraestructuras → Moderado, renta variable global y sectorial → Agresivo. Los umbrales de volatilidad anualizada funcionan como **techos** (no como objetivos), conforme a los requisitos de idoneidad de MiFID II (Directiva 2014/65/EU).

| Ticker  | Nombre                          | Clase de Activo       | Perfil      | Vol. anual |
|---------|---------------------------------|-----------------------|-------------|------------|
| IEAG.AS | iShares Core € Govt Bond        | Renta fija EUR        | Conservador | 4,23%      |
| EUNH.DE | iShares Core EUR Govt Bond      | Renta fija EUR        | Conservador | 5,03%      |
| IBCI.AS | iShares € Inflation-Linked Govt | RF indexada inflación | Conservador | 5,94%      |
| INFR.AS | iShares Global Infrastructure   | Infraestructuras/mix  | Moderado    | 13,80%     |
| IHYG.L  | iShares € High Yield Corp Bond  | RF High Yield         | Moderado    | 6,51%      |
| EXSA.DE | iShares STOXX Europe 600        | RV Europa             | Moderado    | 16,22%     |
| CSPX.L  | iShares Core S&P 500            | RV EE.UU.             | Agresivo    | 15,41%     |
| EQQQ.DE | Invesco NASDAQ-100              | RV NASDAQ             | Agresivo    | 21,44%     |
| EXI2.DE | iShares MSCI World Small Cap    | RV small caps global  | Agresivo    | 15,94%     |

#### 3.2 Análisis de Retornos

Los retornos diarios se calculan como retornos simples (`pct_change()`) sobre precios ajustados descargados vía *yfinance*. Se utilizan retornos simples en lugar de logarítmicos por su interpretabilidad directa (variación porcentual del capital); sin embargo, ambas representaciones convergen para retornos diarios de pequeña magnitud. Los retornos anualizados se calculan multiplicando la media diaria por 252 días de negociación. Los siguientes valores se extraen de los outputs ejecutados del notebook `eda_etfs_ucits.ipynb`:

| Ticker  | CAGR anual | Sharpe | Sortino | MDD     |
|---------|------------|--------|---------|---------|
| IEAG.AS | 1,12%      | 0,28   | 0,36    | -20,51% |
| EUNH.DE | 1,18%      | 0,26   | 0,35    | -22,43% |
| IBCI.AS | 1,72%      | 0,29   | 0,37    | -16,20% |

|         |        |      |      |         |
|---------|--------|------|------|---------|
| INFR.AS | 6,51%  | 0,53 | 0,67 | -34,56% |
| IHYG.L  | 3,27%  | 0,53 | 0,53 | -25,61% |
| EXSA.DE | 7,94%  | 0,55 | 0,68 | -35,70% |
| CSPX.L  | 14,11% | 0,93 | 1,14 | -33,90% |
| EQQQ.DE | 19,36% | 0,93 | 1,21 | -31,30% |
| EXI2.DE | 13,89% | 0,75 | 0,87 | -30,00% |

### 3.3 Análisis de Riesgo

La volatilidad anualizada ( $\sigma = \sigma_{\text{diaria}} \times \sqrt{252}$ ) confirma la ordenación esperada por perfil: los ETFs conservadores se sitúan en el rango [4,23% – 5,94%], los moderados en [6,51% – 16,22%] y los agresivos en [15,41% – 21,44%]. Se detecta un caso de **exceso de volatilidad: EXSA.DE (16,22%)** supera el umbral de 15% establecido para el perfil Moderado. Esto no invalida su inclusión, ya que los umbrales de volatilidad se evalúan a nivel de *cartera agregada* en M3, no por activo individual. No obstante, debe quedar documentado para M3 como restricción de optimización activa.

Los MDD de los ETFs conservadores (IEAG.AS -20,51%, EUNH.DE -22,43%) superan el objetivo declarado de MDD < 8% por activo en la Fase 0. Esto es esperable: el drawdown individual de un activo de renta fija en un período de subida de tipos (2022) no refleja el riesgo de la cartera diversificada. El criterio de evaluación correcto es el drawdown de la cartera construida en M3.

### 3.4 Estructura de Dependencias

La matriz de correlaciones de Pearson sobre retornos diarios revela: (1) un único par con  $\rho > 0,85$  — **IEAG.AS ↔ EUNH.DE** ( $\rho = 0,906$ ) —, por debajo del umbral de exclusión de  $\rho = 0,95$ , por lo que ambos se retienen; (2) los ETFs de renta fija EUR presentan correlaciones muy bajas con la renta variable global (EUNH.DE ↔ EXI2.DE:  $\rho = 0,024$ ; IEAG.AS ↔ EXI2.DE:  $\rho = 0,054$ ), confirmando el efecto diversificador esperado entre perfiles.

Para la estimación de la matriz de covarianza se aplica el estimador de **Ledoit-Wolf** (Ledoit & Wolf, 2004):  $\Sigma_{\text{LW}} = (1-\alpha) \cdot S + \alpha \cdot F$ , donde  $S$  es la covarianza muestral y  $F$  una matriz objetivo estructurada. Con  $N=9$  activos y  $T \approx 4.010$  observaciones, la ratio  $T/N \approx 445$  es elevada, lo que hace que la covarianza muestral sea razonablemente estable. El coeficiente de *shrinkage* estimado resulta  $\alpha = 0,0073$  ( $\|S - \Sigma_{\text{LW}}\|_F / \|S\|_F = 0,67\%$ ), indicando una corrección modesta. Aun con  $\alpha$  pequeño, Ledoit-Wolf se aplica por principio de consistencia metodológica: garantiza que la matriz de covarianza es definida positiva para cualquier  $T/N$ , evitando el riesgo numérico de matrices singulares en la optimización de M3.

### 3.5 Outputs para M3

El notebook `eda_etfs_ucits.ipynb` fue ejecutado completamente y persistió todos los artefactos necesarios para M3. El estado en disco es:

| Artefacto | Ruta | Estado | Contenido |
|-----------|------|--------|-----------|
|-----------|------|--------|-----------|

|                     |            |      |                                               |
|---------------------|------------|------|-----------------------------------------------|
| prices.parquet      | ETFs/      | ■ OK | Precios ajustados diarios (9 ETFs, 2010–2026) |
| returns.parquet     | ETFs/      | ■ OK | Retornos simples diarios (4.010 obs × 9 ETFs) |
| mu.pkl              | ETFs/      | ■ OK | Vector de retornos esperados anualizados      |
| cov_ledoit_wolf.pkl | ETFs/      | ■ OK | Matriz de covarianza Ledoit-Wolf anualizada   |
| selected_etfs.json  | ETFs/data/ | ■ OK | Metadatos de selección con scores por ETF     |

### 3.6 Conclusiones y Criterio de Paso

**Veredicto Go/No-Go para Fase 1B: ■ GO.** Los 9 ETFs disponen de histórico completo desde 2010-09-15, los outputs requeridos por M3 están persistidos y verificados, la diversificación entre perfiles está confirmada por la estructura de correlaciones, y la covarianza Ledoit-Wolf está estimada y disponible. El único punto de atención es la volatilidad de EXSA.DE (16,22% > 15%), que M3 deberá gestionar mediante la restricción de volatilidad de cartera.

## 4. Fase 1C — Cuestionario MiFID II y Personas Sintéticas

### 4.1 Marco Regulatorio

El diseño del cuestionario de perfilado se enmarca en la normativa MiFID II (Directiva 2014/65/EU, Art. 25.2), el Reglamento Delegado 2017/565 (Arts. 54–55) y las Directrices ESMA ESMA35-43-3172. Dicha normativa obliga a las entidades de asesoramiento a recopilar información suficiente del cliente en cuatro dimensiones obligatorias: conocimientos y experiencia inversora, situación financiera, objetivos de inversión y tolerancia al riesgo.

El principio más relevante para el diseño de M1 es el **principio de suelo (floor rule o mínimo denominador)**: el perfil de riesgo final debe ser el más conservador entre todas las dimensiones evaluadas. En otras palabras, una alta tolerancia declarada al riesgo no puede compensar una situación financiera frágil o conocimientos insuficientes. Este principio es idéntico en su lógica a la regla de prudencia asimétrica que implementa M1 en la fusión NLP-cuestionario.

### 4.2 Diseño del Cuestionario (Plantilla C)

Se ha diseñado la **Plantilla C**, un cuestionario de 15 preguntas (12 cerradas + 3 abiertas). Las preguntas cerradas P1–P12 se agrupan en cinco bloques con ponderación adaptativa según el horizonte temporal declarado (P8):

| Bloque | Dimensión MiFID II          | Preguntas | Peso (horizonte largo) |
|--------|-----------------------------|-----------|------------------------|
| B1     | Conocimiento y experiencia  | P1–P3     | 15%                    |
| B2     | Situación financiera        | P4–P7     | 15%                    |
| B3     | Objetivos de inversión      | P8–P11    | 20–45% (adaptativo)    |
| B4     | ESG / restricciones         | P12       | 5%                     |
| B5     | NLP (textos libres P13–P15) | P13–P15   | 10–20% (adaptativo)    |

El scoring final en  $[0, 1]$  se mapea a perfil de riesgo según los siguientes umbrales:  $[0,00–0,40] \rightarrow$  **conservador**,  $(0,40–0,70] \rightarrow$  **moderado**,  $(0,70–1,00] \rightarrow$  **agresivo**. La **floor rule** se activa automáticamente cuando  $P5 \leq 1$  (impacto grave o catastrófico de pérdida total de la inversión) o cuando  $P6 = 0$  (deudas superiores al 50% de los ingresos), asignando perfil conservador con independencia del score numérico calculado.

La pregunta P13 (texto libre en castellano sobre motivaciones de inversión) constituye el diferenciador innovador del sistema: es el punto de entrada del pipeline NLP dual (FinBERT + RoBERTuito) de M1, capturando la preferencia de riesgo *revelada* frente a la preferencia *declarada* de las respuestas cerradas.

### 4.3 Personas Sintéticas (n=30)

Se generaron **30 personas sintéticas** (fichero `personas_sinteticas_M1_plantilla_c.json`) distribuidas equitativamente entre los tres perfiles: 10 conservadores (CO01–CO10), 10 moderados (MO01–MO10) y 10 agresivos (AG01–AG10). De las 30 personas, **10 son perfectamente coherentes** (respuestas y textos forman un retrato consistente del perfil) y

**20 incorporan incoherencias intencionadas** que reproducen patrones reales observados en cuestionarios MiFID II:

| Tipo de incoherencia                                | Personas afectadas     |
|-----------------------------------------------------|------------------------|
| Activación de la floor rule (P5 o P6 críticos)      | CO05, CO06, CO08, CO10 |
| Self-overestimation (Dunning-Kruger)                | CO06                   |
| Inconsistencia P10–P11 (declarada vs real)          | CO07                   |
| NLP contradictorio con respuestas cerradas          | CO08, MO07             |
| Horizon-objective mismatch                          | CO09                   |
| Knowledge-experience mismatch (CFA sin experiencia) | MO04                   |
| Alta varianza intra-NLP                             | MO05, MO06, AG06       |
| Capacidad financiera vs voluntad declarada          | MO06, CO10             |
| ESG estricto vs rentabilidad alta                   | MO09, AG08             |

Tras aplicar el modelo de la Plantilla C a las 30 personas, se observa una coincidencia del **100%** entre el perfil objetivo (definido por construcción) y el perfil calculado por el modelo. La floor rule se activa correctamente en los seis casos diseñados para ello.

#### 4.4 Estado de Implementación

| Entregable                                               | Estado                                 |
|----------------------------------------------------------|----------------------------------------|
| Cuestionario Plantilla C (P1–P12, 12 preguntas cerradas) | ■ Completado                           |
| Preguntas abiertas P13–P15 (input NLP)                   | ■ Completado                           |
| 30 personas sintéticas JSON + XLSX                       | ■ Completado                           |
| Validación 100% perfil esperado vs calculado             | ■ Completado                           |
| Integración con QuestionnaireScorer de m1_profiling.py   | ■■ Pendiente (bloqueado en Fase 1C→M1) |
| Tabla answer_value_table para 11 preguntas               | ■■ Pendiente (congelar tras Fase 1C)   |

## 5. Síntesis y Criterios de Paso de la Fase 1

| Subtarea                      | Estado                               | Criterio Go/No-Go                           | Veredicto |
|-------------------------------|--------------------------------------|---------------------------------------------|-----------|
| 1A — Financial PhraseBank EDA | Completada. 84 celdas ejecutadas.    | Clases sintagmáticas allagree identificado. | <b>GO</b> |
| 1B — EDA ETFs UCITS           | Completada. 30 celdas ejecutadas.    | Historial de 2010, perquisición de          | <b>GO</b> |
| 1C — Cuestionario MiFID II    | Completado por personas competentes. | Integración 100% de perfiles.               | <b>GO</b> |

La cadena de dependencias confirada es: **Fase 1B** → **M3** (outputs de ETFs son el input directo del optimizador de carteras) y **Fase 1C** → **M1** (el cuestionario finalizado y la tabla `answer_value_table` son prerequisite para completar `QuestionnaireScorer.score()`). Los outputs de la Fase 1A (allagree subset, métricas de referencia) están disponibles y verificados para la validación zero-shot de FinBERT en M1.

## Apéndice A — Estadísticos Detallados (Financial PhraseBank)

### A.1 Distribución completa de clases por nivel de agreement (%)

| Nivel    | Frases únicas | negative (%) | neutral (%) | positive (%) |
|----------|---------------|--------------|-------------|--------------|
| 50agree  | 4.838         | 14,40        | 54,50       | 31,10        |
| 66agree  | 4.211         | 12,30        | 50,90       | 36,80        |
| 75agree  | 3.448         | 9,80         | 63,50       | 26,70        |
| allagree | 2.259         | 13,40        | 61,40       | 25,20        |

### A.2 Tabla de tests estadísticos (resumen completo)

| Test                        | H <sub>0</sub>                   | Estadístico     | g.l. | p-valor                | Decisión ( $\alpha=0,05$ )               |
|-----------------------------|----------------------------------|-----------------|------|------------------------|------------------------------------------|
| D'Agostino K <sup>2</sup>   | Normalidad de len_words          | 337,92          | 2    | $4,18 \times 10^{-10}$ | Rechazar H <sub>0</sub>                  |
| Chi <sup>2</sup> de Pearson | label $\perp$ agreement_level    | 56,79           | 6    | < 0,0001               | Rechazar H <sub>0</sub>                  |
| Cramér's V                  | — (tamaño del efecto)            | 0,077           | —    | —                      | Asociación trivial                       |
| Kruskal-Wallis              | Longitud igual en 3 clases       | 65,14           | 2    | $7,15 \times 10^{-14}$ | Rechazar H <sub>0</sub>                  |
| Spearman                    | Longitud $\perp$ agreement_level | $\rho = -0,076$ | —    | $1,39 \times 10^{-10}$ | Rechazar H <sub>0</sub> (efecto trivial) |

### A.3 Estadísticos descriptivos de longitud de frase

| Estadístico    | Longitud (chars) | Longitud (palabras)                  |
|----------------|------------------|--------------------------------------|
| n              | 4.838            | 4.838                                |
| Media          | 128,06           | 23,09                                |
| Mediana        | 119,00           | 21,00                                |
| Desv. est.     | 56,41            | 9,94                                 |
| IQR            | 79,00            | 13,00                                |
| MAD            | 39,00            | 7,00                                 |
| Mínimo         | 9                | 2                                    |
| Máximo         | 315              | 81                                   |
| Percentil 75   | 163,00           | 29,00                                |
| Límite FinBERT | —                | 512 tokens (todos los textos entran) |

## Referencias

---

Araci, D. (2019). FinBERT: Financial Sentiment Analysis with Pre-trained Language Models. *arXiv:1908.10063*.

Ledoit, O. & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.

Malo, P., Sinha, A., Korhonen, P., Wallenius, J. & Takala, P. (2014). Good Debt or Bad Debt: Detecting Semantic Orientations in Economic Texts. *JAS/ST*, 65(4), 782–796.

MiFID II — Directiva 2014/65/UE del Parlamento Europeo y del Consejo relativa a los mercados de instrumentos financieros.

Reglamento Delegado (UE) 2017/565 de la Comisión, Arts. 54–55 (Evaluación de idoneidad).

ESMA35-43-3172 — Guidelines on certain aspects of the MiFID II suitability requirements.

Pérez, J. M. et al. (2021). pysentimiento: A Python Toolkit for Sentiment Analysis and SocialNLP tasks. *arXiv:2106.09462*.

Markowitz, H. (1952). Portfolio Selection. *Journal of Finance*, 7(1), 77–91.

López de Prado, M. (2016). Building Diversified Portfolios that Outperform Out-of-Sample. *Journal of Portfolio Management*, 42(4).