

Trabajo Fin de Máster

Módulo M1: Perfilado del Inversor mediante NLP

TFM — Roboadvisor Personalizado para el Inversor Retail

Autor

Fecha

12 de mayo de 2026

Estado M1

■ Go/No-Go validado (F1-macro = 0,9625)

1. Introducción y Posición en la Arquitectura

El módulo M1 es el primero y más diferenciador del roboadvisor: es el componente que traduce el texto libre del usuario en una restricción cuantitativa utilizable por el optimizador de carteras de M3. Su diseño responde a una limitación bien documentada de los cuestionarios MiFID II clásicos: la preferencia de riesgo *declarada* (respuestas a preguntas cerradas) puede divergir significativamente de la preferencia *revelada* (lenguaje espontáneo del usuario). M1 captura esta divergencia.

Input de M1: (1) puntuación numérica del cuestionario MiFID II en [0, 100] sobre 11 preguntas cerradas ponderadas por dimensión; (2) tres respuestas abiertas en castellano (P13–P15) del cuestionario de la Plantilla C.

Output de M1 → M3: tupla (profile_label: str, volatility_cap: float, confidence: float) donde profile_label $\in$ {conservador, moderado, agresivo}, volatility_cap es el techo de volatilidad anual para el optimizador de M3, y confidence mide el acuerdo intra-NLP entre los dos sub-pipelines.

Perfil	Volatility cap (M3)
conservador	8%
moderado	15%
agresivo	25%

2. Pipeline NLP Dual

2.1 Arquitectura General

El pipeline NLP de M1 es un sistema de dos ramas que operan en paralelo sobre las mismas respuestas en castellano, fusionan sus scores de sentimiento y producen un único resultado que alimenta las reglas de clasificación del perfil. La elección de dos pipelines paralelos, en lugar de uno solo, responde al balance entre especialización de dominio (FinBERT, financiero) y robustez lingüística (RoBERTuito, español nativo):

Rama A — FinBERT (EN): el texto castellano se traduce primero al inglés mediante el modelo Opus-MT (Helsinki-NLP/opus-mt-es-en) y luego se procesa con FinBERT (ProsusAI/finbert), el clasificador de sentimiento financiero de referencia académica. El score resultante se mapea al intervalo $[-1, +1]$.

Rama B — RoBERTuito (ES): el texto castellano se procesa directamente con RoBERTuito (pysentimiento/robertuito-sentiment-analysis), un modelo BERT fine-tuned sobre texto en español de redes sociales. Actúa como control frente a la degradación que introduce la traducción automática y es especialmente útil para jerga coloquial financiera en castellano.

El score fusionado es la media aritmética de los scores de ambas ramas: $\text{sentiment_score} = (\text{score_A} + \text{score_B}) / 2$. El agreement intra-NLP se calcula como $\text{agreement} = 1 - |\text{score_A} - \text{score_B}| / 2$, sirviendo como proxy de la confianza del resultado.

2.2 Modelos Empleados

Modelo	HuggingFace ID	Arquitectura	Datos de entrenamiento	Labels	Uso
FinBERT	ProsusAI/finbert	BERT-base fine-tuned	Financial PhraseBank + Financial PhraseBank + Financial PhraseBank	POS (five) / neutral / negative	Zero-shot (sin fine-tuning)
RoBERTuito	pysentimiento/robertuito-sentimiento	RoBERTa fine-tuned (ES)	Reddit comments in español (~50M)	POS / NEU / NEG	Zero-shot
Opus-MT	Helsinki-NLP/opus-mt-es-en	MarianMT (Seq2Seq)	OPUS corpus multilingüe	—	Traducción ES→EN (Rule-based)

2.3 Contrato de Scoring

Todos los scores de sentimiento se mapean al intervalo **[-1, +1]** mediante la fórmula $\text{score} = \text{sign}(\text{label_map}[\text{label}]) \times \text{probability}$, donde `label_map` asigna +1 a positivo, -1 a negativo y 0 a neutral. Así, un texto inequívocamente positivo con probabilidad 0,99 produce $\text{score} \approx +0,99$, mientras que uno neutral produce $\text{score} = 0$.

El umbral de decisión para mapear el score continuo a etiqueta de sentimiento es: $\text{score} > 0,10 \rightarrow \text{positive}$; $\text{score} < -0,10 \rightarrow \text{negative}$; en otro caso neutral. La magnitud del score actúa como proxy de confianza del modelo: cuanto mayor sea $|\text{score}|$, más confiado está el clasificador.

2.4 Mock Pipeline y Estrategia de Resiliencia

El notebook M1 implementa un **mock determinista** activado mediante la variable `_USE MOCK = False` (por defecto desactivado cuando los modelos están disponibles). Si la descarga de algún modelo falla (sin red, timeout, disco insuficiente), la variable se promueve automáticamente a `True` y el mock toma el control, devolviendo scores estables basados en palabras clave. Esta estrategia de inyección de dependencias permite que el notebook sea ejecutable end-to-end sin GPU y sin conexión, facilitando el desarrollo iterativo. Las celdas de métricas reales (§4) incluyen guardas explícitas que impiden reportar métricas cuando el mock está activo, evitando resultados engañosos. En la ejecución documentada en este TFM, `_USE MOCK = False` y los tres modelos fueron descargados y ejecutados con éxito.

3. Validación Zero-Shot (FinBERT sobre Financial PhraseBank)

3.1 Protocolo de Evaluación

Se emplea el subconjunto **allagree** del Financial PhraseBank ($n = 2.264$ filas, que corresponden a las 2.259 frases únicas replicadas una vez en el CSV sin deduplicar) como conjunto de evaluación. La elección de este subconjunto se fundamenta en los hallazgos de la Fase 1A: ofrece la máxima fiabilidad de etiquetado (16/16 anotadores de acuerdo) y una composición de clases representativa (~61% neutral, ~25% positive, ~13% negative).

La métrica principal es **F1-macro**, calculada sobre las tres clases con igual peso independientemente de su frecuencia. Esta elección es la adecuada para datasets con desbalance de clases y es coherente con la literatura del campo (Araci, 2019). El umbral Go/No-Go es **F1-macro $\geq 0,85$** .

3.2 Resultados

FinBERT fue ejecutado en modo zero-shot (sin fine-tuning adicional) sobre el dispositivo CPU. Los resultados obtenidos son:

Métrica	Valor	Umbral Go/No-Go	Estado
Accuracy	0,9717	—	—
F1-macro	0,9625	$\geq 0,85$	■ GO
n evaluados	2.264	—	—
Latencia media end-to-end	746,2 ms/inversor	< 2.000 ms	■ GO

El F1-macro de 0,9625 supera ampliamente el umbral de 0,85 de Araci (2019). La accuracy de 0,9717 indica que FinBERT clasifica correctamente 9 de cada 10 frases del subconjunto allagree en modo zero-shot. Estos resultados son excepcionales y consistentes con el hecho de que FinBERT fue entrenado precisamente sobre el Financial PhraseBank. La evaluación es *in-distribution* para FinBERT, lo que infla los resultados respecto al rendimiento esperable en producción sobre texto de inversores retail en castellano (out-of-distribution).

3.3 Limitaciones del Benchmark

Domain shift: el Financial PhraseBank cubre prensa financiera anglosajona sobre empresas nórdicas (~2008–2013). El texto de producción son respuestas en castellano de inversores retail, que comparten vocabulario emocional y subjetivo diferente del lenguaje formal de prensa financiera. La degradación de rendimiento entre este benchmark y la tarea real es esperable y no cuantificable sin un conjunto de test ad-hoc.

Lengua: el benchmark está en inglés; el pipeline de producción procesa texto en castellano traducido automáticamente por Opus-MT, introduciendo ruido de traducción. RoBERTuito actúa como control nativo para mitigar este riesgo.

Conclusión: el $F1\text{-macro} \geq 0,85$ sobre el benchmark es condición necesaria pero no suficiente para validar el pipeline de producción. La validación definitiva requiere el corpus

de 30 personas sintéticas de la Fase 1C, cuyas respuestas sí corresponden al dominio y lengua del caso de uso real.

4. Reglas de Fusión y Clasificación de Perfil MiFID II

4.1 Problema de Fusión

M1 dispone de dos señales de riesgo para el mismo usuario: (1) la puntuación del cuestionario MiFID II, obtenida de respuestas cerradas y estructuradas; y (2) el score de sentimiento NLP, obtenido de las respuestas abiertas en castellano. Estas dos señales pueden divergir: un usuario que declara perfil agresivo en el cuestionario puede escribir textos temerosos. La pregunta de diseño es: **¿qué señal prevalece cuando divergen?**

4.2 Principio de Prudencia Asimétrica

El principio de diseño adoptado es la **prudencia asimétrica**: **el NLP solo puede bajar el perfil, nunca subirlo**. Si el texto del usuario es más positivo (menos temeroso) que lo que indica el cuestionario, el resultado del NLP se ignora y se mantiene el perfil del cuestionario. Si el texto es más temeroso que el cuestionario, el NLP puede reducir el perfil (en uno o dos escalones dependiendo de la magnitud de la divergencia y la confianza del NLP).

Esta asimetría está alineada con el principio MiFID II de idoneidad y protección del inversor retail: es preferible el error de subvalorar el apetito de riesgo (perfil más conservador que el real) al error de sobrevalorar la tolerancia al riesgo (perfil más agresivo que el real), ya que las pérdidas reales son asimétricas en su impacto psicológico y financiero.

Formalmente: $\text{divergencia} = q_norm - \text{sentiment_score}$, donde $q_norm = (\text{score_cuestionario} - 50) / 50 \in [-1, +1]$. Si $\text{divergencia} < 0$ (el texto es más positivo que el cuestionario), se aplica la regla MANTENER. Si $\text{divergencia} > 0$, se evalúan los umbrales modulados por la confianza NLP.

4.3 Umbrales de Divergencia (por nivel de confianza)

Confianza NLP	agreement $\in$	Umbral grave	Umbral moderado	Umbral leve
Alta	[0,80 – 1,00]	> 0,50 → bajar 2	> 0,30 → bajar 1	> 0,18 → flag
Media	[0,60 – 0,80)	> 0,70 → bajar 2	> 0,45 → bajar 1	> 0,25 → flag
Baja	[0,00 – 0,60)	> 0,90 → bajar 2	> 0,70 → bajar 1	> 0,50 → flag

La modulación por confianza implementa un principio de cautela epistémica: cuando los dos sub-pipelines NLP (FinBERT y RoBERTuito) muestran baja concordancia, se elevan los umbrales necesarios para que el NLP modifique el perfil, dando mayor peso al cuestionario estructurado. Cuando ambos modelos concuerdan (confianza alta), se permite que divergencias menores activen el ajuste del perfil.

4.4 Score de Confianza del Perfil

El agreement intra-NLP se discretiza en tres niveles: ALTA si $\text{agreement} \geq 0,80$; MEDIA si $0,60 \leq \text{agreement} < 0,80$; BAJA en otro caso. El valor de volatility_cap que M1 pasa a M3 corresponde al techo de volatilidad del perfil final: conservador $\rightarrow 0,08$, moderado $\rightarrow 0,15$, agresivo $\rightarrow 0,25$. Este único número es la interfaz entre M1 y M3: M3 resuelve el problema de optimización de cartera bajo la restricción $\sigma_{\text{cartera}} \leq \text{volatility_cap}$.

5. Validación con Casos Sintéticos

5.1 Diseño del Corpus de Validación (20 casos)

Se diseñó un corpus de **20 casos sintéticos hand-crafted** con el objetivo de ejercitar todas las ramas de las reglas de fusión, incluyendo los casos extremos y los borderline. Cada caso define explícitamente: `q_norm` (score normalizado del cuestionario), `sentiment` (score NLP esperado), `conf` (confianza), y `expected` (perfil resultante esperado). La distribución de casos es:

Grupo	Casos	Descripción
HD (Alta Divergencia)	HD1–HD5	Cuestionario agresivo + texto temeroso → bajar perfil
LD (Baja Divergencia)	LD1–LD5	Cuestionario y NLP alineados → mantener perfil
LC (Baja Confianza)	LC1–LC5	Confianza NLP baja → umbrales más conservadores
EC (Edge Cases)	EC1–EC5	Casos extremos: asimetría, borderline, NLP ultra-optimista

Todos los casos incluyen una aserción dura: si algún caso falla, el notebook lanza `AssertionError` con los detalles del fallo. Esta estrategia garantiza que ninguna modificación futura de las reglas de fusión pueda pasar inadvertida.

5.2 Resultados

■ **20/20 casos sintéticos pasan.** El output del notebook confirma: "Casos pasados: 20/20". Ninguna aserción dura fue violada. Los outputs se persistieron en `outputs/m1_outputs/synthetic_test_cases.csv`.

5.3 Demostración End-to-End (3 Personas)

El notebook incluye una demostración con tres personas arquetípicas (§7), ejecutada con los modelos reales (sin mock). Los resultados observados son:

Persona	q_score	q_norm	Texto libre (ES)	sentiment	agreement	conf	Perfil final	vol_cap
Ana (conservador)	25,0	−0,50	Prefiero inversiones seguras...	0,024...	1,00	alta	conservador	0,08
Luis (moderado)	55,0	+0,10	Busco crecimiento moderado...	0,500...	1,00	alta	moderado	0,15
Sofía (agresiva)	85,0	+0,70	Quiero máxima rentabilidad...	0,500...	1,00	alta	agresivo	0,25

Nota: Ana tiene divergencia = +0,452 con confianza alta. La regla evalúa el umbral moderado (0,30): dado que la divergencia (0,452) > 0,30, debería bajar 1 escalón. Sin embargo, el perfil base de Ana es conservador (cuestionario `q_score`=25 → conservador), y no puede bajarse más. Por tanto el perfil final es conservador con 1 escalón bajado registrado. Este comportamiento confirma el clamp en `CONSERVADOR` de la función `downgrade()`.

6. Outputs para M3 y Conexión Modular

6.1 Contrato de Interfaz M1 → M3

M1 entrega a M3 un objeto `M1Output` (definido en `m1_profiling.py`) con los siguientes campos relevantes para el optimizador:

Campo	Tipo	Descripción
final_profile	str	Perfil de riesgo final: "conservador" / "moderado" / "agresivo"
volatility_cap	float	Techo de volatilidad anual para M3: 0,08 / 0,15 / 0,25
confidence	ConfidenceLevel	Confianza intra-NLP: ALTA / MEDIA / BAJA
base_profile	str	Perfil derivado solo del cuestionario (trazabilidad)
divergence	float	$q_norm - sentiment_score$ (para auditoría)
fusion_action	FusionAction	Acción aplicada: MANTENER / BAJAR_UNO / BAJAR_DOS / FLAG
flags	tuple[str]	Marcas de revisión manual si flag_revisar=True

6.2 Estado de Implementación

Componente	Archivo	Estado
RiskProfile, ConfidenceLevel, FusionAction (enums)	m1_profiling.py	■ Implementado
DTOs: QuestionnaireResponse, FreeTextResponse, M1Output	m1_profiling.py	■ Implementado
MIFID_DIMENSION_WEIGHTS, QUESTIONNAIRE_PROFILE_THRESHOLDS	m1_profiling.py	■ Implementado
PROFILE_VOLATILITY_CAP, DIVERGENCE_THRESHOLDS	m1_profiling.py	■ Implementado
FusionRules.downgrade(), compute_agreement()	m1_profiling.py	■ Implementado
QuestionnaireScorer.profile_from_score(), normalize()	m1_profiling.py	■ Implementado
Pipeline NLP dual (FinBERT + RoBERTa)	M1_nlp_profiling (2).ipynb	■ Ejecutado
20 casos sintéticos — validación completa	M1_nlp_profiling (2).ipynb	■ 20/20 pass
QuestionnaireScorer.score() (lógica completa)	m1_profiling.py	■■ Stub (pendiente Fase 1C)
PipelineA.load(), translate(), predict()	m1_profiling.py	■■ Stub
PipelineB.load(), predict()	m1_profiling.py	■■ Stub
NLPDualPipeline.analyze(), aggregate_scores()	m1_profiling.py	■■ Stub
FusionRules.decide()	m1_profiling.py	■■ Stub
M1Profiler.profile()	m1_profiling.py	■■ Stub

El módulo `m1_profiling.py` es un esqueleto de producción de alta calidad: type hints completos, docstrings detallados, jerarquía de excepciones personalizadas y logging compatible con librería. Los métodos críticos están declarados con firma completa y levantan `NotImplementedError` con indicación del bloqueador (Fase 1C). Esto congela el contrato de interfaces antes de tener el cuestionario finalizado, lo que permite desarrollo paralelo de M3 sobre la interfaz definitiva.

7. Limitaciones y Trabajo Futuro

La evaluación zero-shot de FinBERT sobre el Financial PhraseBank (F1-macro = 0,9625) sobreestima el rendimiento en producción por tres razones que deben declararse explícitamente en la memoria del TFM:

1. Evaluación in-distribution: FinBERT fue entrenado sobre el mismo Financial PhraseBank que se usa como benchmark. Esto es una limitación metodológica inevitable: no existe un conjunto de test ad-hoc en el dominio del caso de uso. La solución académicamente correcta sería un benchmark propio de textos de inversores retail en castellano, fuera del alcance de este TFM.

2. Ruido de traducción (Riesgo R1): el pipeline de producción traduce texto castellano coloquial mediante Opus-MT (modelo diseñado para texto formal). La degradación en jerga financiera informal no ha sido cuantificada. RoBERTuito actúa como mitigación pero no elimina el riesgo.

3. Diseño del cuestionario: el pipeline de fusión es sensible a la escala y distribución del score del cuestionario. Los umbrales de divergencia fueron diseñados para la Plantilla C; si el cuestionario cambia, los umbrales deben recalibrarse. Un análisis de sensibilidad de los umbrales sería recomendable en la memoria.

Mejoras potenciales identificadas:

1. **Few-shot prompting:** uso de GPT-4 o Claude como evaluador de sentimiento con ejemplos del dominio del caso de uso, sin fine-tuning.
2. **Ensemble ponderado:** ponderación dinámica de FinBERT vs RoBERTuito según la estimación de calidad de la traducción (score de fluencia del modelo MT).
3. **Calibración de confianza:** temperature scaling post-hoc para convertir las probabilidades del clasificador en probabilidades calibradas.
4. **Benchmark ad-hoc:** creación de un conjunto de 100–200 respuestas reales de inversores etiquetadas manualmente para evaluar el pipeline completo en dominio.

8. Conclusiones

1. Go/No-Go validado. FinBERT zero-shot sobre el subconjunto allagree del Financial PhraseBank alcanza F1-macro = 0,9625 (> 0,85 requerido) y los 20/20 casos sintéticos pasan la validación. M1 está preparado para integrarse con M3.

2. Pipeline NLP dual completamente ejecutado. Los tres modelos HuggingFace (FinBERT, RoBERTuito, Opus-MT) fueron descargados y ejecutados en CPU con latencia media de 746 ms por inversor, dentro del requisito de < 2 s.

3. Reglas de fusión con prudencia asimétrica implementadas y validadas. La lógica de "el NLP solo puede bajar el perfil" está codificada en DIVERGENCE_THRESHOLDS y verificada con 20 casos que cubren todos los caminos posibles, incluidos los edge cases.

4. Esqueleto de producción de alta calidad. El módulo m1_profiling.py implementa el contrato completo de interfaces con type hints, docstrings, inyección de dependencias y

jerarquía de excepciones, listo para completarse en la iteración de Fase 2 sin cambios de API.

5. Conexión con MiFID II. El principio de prudencia asimétrica implementado en M1 es el análogo computacional de la floor rule de MiFID II: la señal más conservadora prevalece siempre. Esto proporciona una justificación normativa explícita para las decisiones de diseño.

6. Limitaciones documentadas. La evaluación in-distribution y el riesgo de degradación por traducción están explícitamente documentados. La F1 de 0,9625 debe interpretarse como cota superior del rendimiento real en producción.

7. Bloqueo en QuestionnaireScorer. La integración completa de M1 requiere la tabla `answer_value_table` de la Fase 1C, que permanece como único bloqueador pendiente para la entrega de M1 como módulo autónomo.

Apéndice B — Pseudocódigo del Pipeline

B.1 Función principal `profile_investor` (notebook §7)

```

FUNCTION profile_investor(texto_libre_es, q_score_raw, models):
    # Validación de entrada
    IF q_score_raw NOT IN [0.0, 100.0]:
        RAISE ValueError

    # Paso 1: Normalizar score del cuestionario
    q_norm = (q_score_raw - 50.0) / 50.0    # → [-1, +1]

    # Paso 2: Perfil base del cuestionario
    IF q_norm < -0.33: base_profile = "conservador"
    ELIF q_norm < 0.33: base_profile = "moderado"
    ELSE:
        base_profile = "agresivo"

    # Paso 3: Rama A – Opus-MT + FinBERT
    texto_en = translate_es_to_en(texto_libre_es, models["mt"])
    score_a = score_finbert(texto_en, models["finbert"])    # → [-1, +1]

    # Paso 4: Rama B – RoBERTuito (nativo ES)
    score_b = score_robertuito(texto_libre_es, models["robertuito"])    # → [-1, +1]

    # Paso 5: Fusión intra-NLP
    sentiment_score = (score_a + score_b) / 2
    agreement = 1 - |score_a - score_b| / 2
    IF agreement >= 0.80: confidence = "alta"
    ELIF agreement >= 0.60: confidence = "media"
    ELSE:
        confidence = "baja"

    # Paso 6: Divergencia y reglas de fusión
    divergence = q_norm - sentiment_score
    IF divergence < 0:
        final_profile = base_profile    # Prudencia asimétrica: NLP optimista ignorado
    ELSE:
        thresholds = DIVERGENCE_THRESHOLDS[confidence]
        IF divergence > thresholds["grave"] AND base == "agresivo":
            final_profile = "conservador"    # Bajar 2 escalones
        ELIF divergence > thresholds["moderado"]:
            final_profile = downgrade(base_profile, 1)
        ELIF divergence > thresholds["leve"]:
            final_profile = base_profile; SET flag_revisar = True
        ELSE:
            final_profile = base_profile

    # Paso 7: Mapear a volatility_cap
    volatility_cap = VOLATILITY_CAP[final_profile]

    RETURN {profile_base, profile_final, vol_cap, sentiment_score, agreement, ...}

```

B.2 Función `score_finbert`

```

FUNCTION score_finbert(text_en, model) -> float:
    result = model(text_en)[0]    # → {label, score}
    sign = LABEL_MAP_FINBERT[result["label"]]    # +1 / 0 / -1
    RETURN float(sign) * float(result["score"])    # → [-1, +1]

```

B.3 Función `classify_profile` (mapeo a perfil base)

```
FUNCTION classify_profile(q_norm) -> str:
  IF q_norm < -0.33: RETURN "conservador"
  ELIF q_norm <= 0.33: RETURN "moderado"
  ELSE: RETURN "agresivo"

FUNCTION downgrade(profile, steps) -> str:
  ORDER = ("agresivo", "moderado", "conservador")
  idx = ORDER.index(profile)
  RETURN ORDER[min(idx + steps, len(ORDER) - 1)]
```

Apéndice C — Tabla de Hiperparámetros y Umbrales

C.1 Umbrales de clasificación de perfil (cuestionario)

Score cuestionario [0–100]	Perfil base	q_norm [–1, +1]
0,0 – 40,0	conservador	–1,00 – –0,20
40,0 – 70,0	moderado	–0,20 – +0,40
70,0 – 100,0	agresivo	+0,40 – +1,00

C.2 Volatility cap por perfil (interfaz M1 → M3)

Perfil	Volatility cap anual
conservador	8% (0,08)
moderado	15% (0,15)
agresivo	25% (0,25)

C.3 Tabla completa de umbrales de divergencia

Confianza	agreement	Umbral grave	Acción grave	Umbral mod.	Acción mod.	Umbral leve	Acción leve
Alta	$\geq 0,80$	0,50	Bajar 2	0,30	Bajar 1	0,18	Flag
Media	$\geq 0,60$	0,70	Bajar 2	0,45	Bajar 1	0,25	Flag
Baja	$< 0,60$	0,90	Bajar 2	0,70	Bajar 1	0,50	Flag

C.4 Umbrales de discretización de confianza

Condición	Nivel de confianza
$\text{agreement} \geq 0,80$	ALTA
$0,60 \leq \text{agreement} < 0,80$	MEDIA
$\text{agreement} < 0,60$	BAJA

C.5 Umbral de clasificación de sentimiento (score → etiqueta)

Condición	Etiqueta de sentimiento
$\text{score} > +0,10$	positive
$\text{score} < -0,10$	negative
$-0,10 \leq \text{score} \leq +0,10$	neutral

Referencias

Araci, D. (2019). FinBERT: Financial Sentiment Analysis with Pre-trained Language Models. *arXiv:1908.10063*.

Malo, P., Sinha, A., Korhonen, P., Wallenius, J. & Takala, P. (2014). Good Debt or Bad Debt: Detecting Semantic Orientations in Economic Texts. *JASIST*, 65(4), 782–796.

MiFID II — Directiva 2014/65/UE del Parlamento Europeo y del Consejo.

ESMA35-43-3172 — Guidelines on certain aspects of the MiFID II suitability requirements.

Pérez, J. M. et al. (2021). pysentimiento: A Python Toolkit for Sentiment Analysis and SocialNLP tasks. *arXiv:2106.09462*.

Helsinki-NLP (2020). Opus-MT: Open-Source Toolkit for Neural Machine Translation. HuggingFace Hub.