

Memoria de Análisis

Exploratorio de Datos

Universo de ETFs UCITS para construcción de carteras multiperfil

Fase del TFM	Fase 1 — Módulo M2 (EDA)
Notebook	eda_etfs_ucits.ipynb
Período de datos	2010-09-06 → 2026-04-24 (15.92 años)
Universo	9 ETFs UCITS multiclase
Outputs M3	returns.parquet · mu.pkl · cov_ledoit_wolf.pkl
Autor	Juan Rilo
Fecha	25 de abril de 2026

Propósito de este documento

Documentar de forma reproducible el proceso de análisis exploratorio realizado sobre el universo de 9 ETFs UCITS, las decisiones metodológicas tomadas, los hallazgos relevantes y los inputs estadísticos generados para alimentar el módulo de optimización de carteras (M3).



Índice

1.	Objetivos y alcance	3
2.	Universo de ETFs seleccionado	3
3.	Descarga y carga de datos	4
4.	Calidad de datos y limpieza	5
5.	Retornos diarios y momentos	6
6.	Volatilidad anualizada	7
7.	Matriz de correlaciones	8
8.	Matriz de covarianza con Ledoit-Wolf	9
9.	Análisis de drawdowns	10
10.	Comparativa frente a benchmarks	10
11.	Decisiones metodológicas — síntesis	11
12.	Veredicto Go/No-Go de Fase 1	12
13.	Outputs y trazabilidad para M3	12

1 Objetivos y alcance

El presente análisis exploratorio constituye la fase de validación previa a la optimización de carteras del TFM. Su objetivo es triple: (i) verificar la idoneidad estadística del universo de ETFs preseleccionado en la Fase 0, (ii) caracterizar el comportamiento histórico de cada activo en términos de retorno, riesgo, asimetría y comovimiento, y (iii) generar los inputs depurados que consumirá el motor de optimización (M3) sin necesidad de reprocesado posterior.

Hipótesis a validar

- Los 9 ETFs disponen de historia común suficiente (≥ 10 años) para estimar momentos de forma robusta.
- Cada ETF se sitúa, en términos de volatilidad y drawdown, en el rango esperado para su clase de activo.
- El universo presenta diversidad de comovimiento suficiente para construir carteras eficientes.
- La covarianza muestral es razonablemente estable o, en caso contrario, el shrinkage de Ledoit-Wolf la regulariza.

Criterio de éxito de la fase

La fase se considera **superada** cuando: (1) todos los ETFs cuentan con datos limpios desde la fecha común de inicio, (2) no se observan pares con correlación > 0.95 (redundancia crítica), (3) la matriz Σ resultante es definida positiva, y (4) los outputs μ y Σ quedan persistidos y reproducibles.

2 Universo de ETFs seleccionado

El universo se compone de 9 ETFs UCITS cotizados en mercados europeos, seleccionados por su liquidez, replicabilidad física, costes ajustados ($TER < 0.50\%$) y por cubrir las principales clases de activo necesarias para construir tres perfiles de inversor: conservador, moderado y agresivo.

Ticker	Nombre	Clase de activo	Perfil
IBGS.AS	iShares EUR Govt Bond 1-3yr	RF soberana corto EUR	Conservador
IEAG.AS	iShares Core EUR Govt Bond	RF soberana agregada EUR	Conservador
EUNH.DE	iShares Core EUR Corp Bond IG	RF corporativa IG EUR	Conservador / Moderado
IHYG.L	iShares EUR High Yield Corp	RF high yield EUR	Moderado
EXSA.DE	iShares STOXX Europe 600	RV Europa	Moderado / Agresivo
INFR.AS	iShares Global Infrastructure	Infraestructura (real)	Moderado
IEEM.L	iShares MSCI EM (Dist)	RV emergentes	Agresivo
IWDA.AS	iShares Core MSCI World	RV global desarrollada	Moderado / Agresivo
EQQQ.DE	Invesco Nasdaq-100 UCITS	RV tecnológica US	Agresivo

Tabla 1. Universo definitivo del estudio. Sustitución de IQQP.DE (Property, $\sigma=18.5\%$) por INFR.AS (Infrastructure, $\sigma=13.8\%$) — véase decisión D7.

3 Descarga y carga de datos

Los precios diarios ajustados (dividendos y splits) se obtienen mediante *yfinance* con parámetro `auto_adjust=True`, desde el 1 de enero de 2010 hasta la fecha de ejecución. La columna utilizada es `Close`, ya ajustada por dividendos y splits, lo que garantiza retornos totales comparables.

Decisión: precios ajustados frente a precios crudos

Se opta por precios ajustados porque la métrica de interés es el **retorno total al inversor**, no la cotización nominal. Para ETFs de distribución (como IEEM.L) ignorar dividendos infravaloraría sistemáticamente el retorno.

Inspección inicial

Ticker	Primera fecha disponible	% missing pre-limpieza
IBGS.AS	2010-01-04	0.29%
IEAG.AS	2010-01-04	0.26%
EUNH.DE	2010-01-04	1.03%
IHYG.L	2010-09-03	5.59%
EXSA.DE	2010-01-04	1.08%
INFR.AS	2010-01-04	0.31%
IEEM.L	2010-01-04	1.60%
IWDA.AS	2010-01-04	0.29%
EQQQ.DE	2010-01-04	1.08%

Tabla 2. Cobertura inicial por ticker.

Hallazgo · IHYG.L marca el inicio común

IHYG.L (high yield EUR) es el ETF con cotización más tardía: 3 de septiembre de 2010. Esto fija el período común a partir del cual se realizan todos los cálculos: **2010-09-06 a 2026-04-24**. Se acepta esta restricción ya que aún quedan **15.92 años** de historia, holgadamente por encima del umbral de 10 años establecido como criterio go/no-go.

4 Calidad de datos y limpieza

Se aplican tres pasos de limpieza, en orden:

① Forward-fill limitado

Los días de festivo cruzados entre mercados (LSE, Xetra, Euronext) generan NaN aislados. Se aplica `ffill(limit=3)`: rellenar como máximo 3 días consecutivos. Esto absorbe el calendario sin enmascarar suspensiones de cotización reales.

② Recorte al período común

Se descartan las fechas anteriores a la primera observación válida del último ETF en incorporarse (IHYG.L, 2010-09-06). El resultado son 4 012 observaciones diarias completas para los 9 activos.

③ Filtro de bad ticks (decisión crítica)

La inspección posterior reveló **anomalías evidentes en EQQQ.DE**: precios aislados que se desviaban más del 30 % del baseline durante una sola sesión y volvían el día siguiente (p. ej., 2011-06-02: salto del precio

normal ~37 € a 53 €). Sin filtrado, la volatilidad anualizada inflaba a 38.8 %, frente al 21 % real, y la correlación con IWDA caía a 0.41 (debería estar próxima a 0.78).

Regla aplicada

Se marca como bad tick cualquier observación cuyo retorno frente al día anterior **y** frente al día siguiente exceda el ± 20 % en valor absoluto, con signos coherentes con un round-trip (spike-y-vuelta). Estas observaciones se sustituyen por NaN y se rellenan vía forward-fill. El filtro corrigió 7 ticks en EQQQ.DE concentrados en 2011, sin afectar a ningún otro ticker.

El umbral del 20 % es deliberadamente conservador: ni siquiera el lunes negro del COVID (16-marzo-2020, -12 % en S&P 500) lo cruzaría.

5 Retornos diarios y momentos

Se calculan los retornos simples mediante `pct_change()`. Se prefieren a los logarítmicos porque la teoría de carteras de Markowitz que se aplicará en M3 asume retornos aritméticos: el retorno de la cartera es la combinación lineal ponderada de los retornos de los activos, propiedad que solo cumple $r = \Delta p/p$.

Ticker	μ anual	σ diaria	Skewness	Kurtosis exc.
IBGS.AS	0.76%	0.13%	−1.02	31.9
IEAG.AS	1.17%	0.28%	−0.63	12.9
EUNH.DE	1.26%	0.32%	−0.07	7.6
IHYG.L	3.54%	0.42%	−2.39	56.3
EXSA.DE	9.03%	1.02%	−0.78	10.3
INFR.AS	7.15%	0.87%	−0.76	10.3
IEEM.L	5.57%	1.16%	−0.36	4.9
IWDA.AS	12.38%	0.96%	−0.53	7.0
EQQQ.DE	20.15%	1.35%	+1.22	65.4

Tabla 3. Estadísticos descriptivos de los retornos diarios. μ anualizado $\times 252$.

Hallazgos clave

- **Fat tails universales:** todos los ETFs presentan kurtosis exceso significativamente positiva (rango 4.9–65.4). Los retornos no son normales; los percentiles extremos están infraestimados por una distribución gaussiana. Justifica usar HRP o métricas robustas en M3 además de Markowitz puro.
- **Asimetría negativa generalizada en RF:** IHYG.L (−2.39) e IBGS.AS (−1.02) presentan la cola izquierda más severa, coherente con riesgo de eventos de crédito y tipos.
- **EQQQ.DE positivamente asimétrico:** skew = +1.22, dominado por días de fuerte rebote tecnológico — consistente con la era post-2010 del Nasdaq.
- **Coherencia con clase de activo:** los retornos medios anualizados encajan con expectativas académicas: RF EUR ≈ 0 –4 %, RV global desarrollada ≈ 9 –12 %, infraestructura ≈ 7 %, Nasdaq ≈ 20 %.

6 Volatilidad anualizada

La volatilidad anualizada se obtiene como $\sigma_{\text{diaria}} \times \sqrt{252}$, asumiendo independencia entre observaciones consecutivas (la autocorrelación serial de retornos diarios de ETFs líquidos es estadísticamente despreciable).

Perfil esperado	Ticker	σ anual	Encaja en perfil
Conservador (< 8%)	IBGS.AS	1.99%	✓
Conservador	IEAG.AS	4.37%	✓
Conservador	EUNH.DE	5.14%	✓
Moderado (8 – 18%)	IHYG.L	6.58%	✓ (límite bajo)
Moderado / Agresivo	EXSA.DE	16.19%	✓
Moderado (diversific.)	INFR.AS	13.78%	✓

Perfil esperado	Ticker	σ anual	Encaja en perfil
Agresivo (> 15%)	IEEM.L	18.46%	✓
Moderado / Agresivo	IWDA.AS	15.20%	✓
Agresivo	EQQQ.DE	21.36%	✓

Tabla 4. Volatilidad anualizada por ETF y validación frente al perfil objetivo.

Validación · Universo coherente con el diseño de perfiles

Tras la sustitución de IQQP.DE por INFR.AS, los **9 ETFs encajan en su perfil objetivo**. INFR.AS aporta exposición a infraestructura global (real assets) con $\sigma = 13.78 \%$, propia de un activo de riesgo moderado, no de un equity emergente disfrazado.

7 Matriz de correlaciones

Se calcula la correlación de Pearson sobre retornos diarios. Es la métrica estándar para input directo en optimización media-varianza. La interpretación se centra en dos extremos: pares con $\rho > 0.85$ (redundancia) y pares con $\rho < 0.20$ (diversificadores eficientes).

Pares con $\rho > 0.85$ — redundancia potencial

Par	ρ	Interpretación
IEAG.AS / EUNH.DE	0.91	Govt EUR vs Corp IG EUR — duración y curva de tipos comunes
EXSA.DE / IWDA.AS	0.87	Europa pesa ~17 % en MSCI World; comovimiento estructural

Pares con $\rho < 0.10$ — diversificadores eficientes

Par	ρ	Interpretación
EUNH.DE / IEEM.L	0.01	Crédito IG europeo vs RV emergente — vehículos de riesgo distintos
IEAG.AS / IEEM.L	0.03	RF soberana EUR descorrelacionada de emergentes
EUNH.DE / IWDA.AS	0.04	Crédito IG y RV global desarrollada actúan en regímenes opuestos
EUNH.DE / EQQQ.DE	0.04	Excelente complemento defensivo de la cartera tecnológica
IBGS.AS / EQQQ.DE	0.06	RF corto vs Nasdaq — descorrelación clásica risk-on/risk-off

INFR.AS · perfil de correlaciones

INFR.AS muestra ρ moderada con renta variable global (0.77 con IWDA, 0.67 con EXSA), pero **baja con renta fija EUR** (0.12 con IBGS, 0.17 con IEAG, 0.15 con EUNH). Este perfil lo convierte en un complemento eficiente para el bloque defensivo de las carteras moderadas: aporta retorno tipo equity con escasa correlación con el grueso de la RF, mejorando la frontera eficiente.

Decisión · Mantener IEAG y EUNH a pesar de $\rho = 0.91$

A pesar de su elevada correlación, ambos ETFs cumplen funciones distintas en términos de exposición (soberano vs. corporativo IG). El optimizador en M3 tendrá libertad para asignar peso cero a uno de ellos si la frontera eficiente lo dicta. Se prefiere ofrecer al motor un universo ligeramente redundante que cercenarlo arbitrariamente.

8 Matriz de covarianza con Ledoit-Wolf

La covarianza muestral es un estimador insesgado pero altamente **ruidoso** cuando el número de activos N es grande relativo a las observaciones T . Pequeños errores en Σ se amplifican en pesos extremos al invertir la matriz dentro del problema de Markowitz. Para mitigarlo se aplica el shrinkage de Ledoit-Wolf:

$$\Sigma_{LW} = (1 - \alpha) \cdot S + \alpha \cdot F$$

donde S es la covarianza muestral, F es un target estructurado (matriz con varianzas en la diagonal y correlación promedio fuera de ella) y α es el coeficiente óptimo de mezcla, estimado analíticamente según Ledoit y Wolf (2004).

Resultado obtenido

Métrica	Valor	Lectura
Coeficiente α	0.0073	Muy bajo: la muestral es ya bastante estable

Métrica	Valor	Lectura
$\ S - \Sigma_{LW}\ _F / \ S\ _F$	< 1%	Σ apenas se modifica respecto a la muestral
Σ_{LW} definida positiva	Sí	Apta como input directo del optimizador en M3

Justificación de mantener Ledoit-Wolf pese a α bajo

Con $T \approx 4\,012$ observaciones y $N = 9$ activos, el ratio T/N es elevado y la muestral es razonablemente estable, lo que explica el α reducido. Aún así, se conserva el estimador shrinked como input de M3 por tres motivos: (i) garantía formal de matriz definida positiva, (ii) coste computacional nulo, (iii) coherencia metodológica con la literatura de carteras robustas — defensible académicamente.

9 Análisis de drawdowns

El drawdown se calcula como la caída relativa desde el máximo histórico acumulado: $DD_t = P_t / \max(P_{t \leq t}) - 1$. El máximo drawdown (MDD) cuantifica la pérdida más severa que un inversor habría sufrido manteniendo el ETF de forma continua.

Ticker	MDD	Fecha	Episodio dominante
IBGS.AS	-6.15%	2023-03-07	Subida de tipos BCE
IEAG.AS	-20.51%	2022-10-21	Peor año histórico para soberanos EUR (2022)
EUNH.DE	-22.43%	2023-09-28	Crédito IG; tipos altos sostenidos
IHYG.L	-25.61%	2020-03-18	COVID 2020
EXSA.DE	-35.70%	2020-03-18	COVID 2020
INFR.AS	-34.56%	2020-03-23	COVID 2020 (utilities y transporte)
IEEM.L	-37.41%	2016-01-20	Devaluación CNY / sell-off emergentes
IWDA.AS	-33.63%	2020-03-23	COVID 2020
EQQQ.DE	-31.30%	2022-12-28	Bear tecnológico 2022

Tabla 5. Máximo drawdown observado en el período común y episodio responsable.

Mensaje clave para la memoria al cliente final: **incluso los activos calificados como conservadores han experimentado pérdidas significativas en escenarios concretos** (IEAG -20.5% en 2022 al subir el BCE los tipos, EUNH -22.4% en 2023). Las expectativas de drawdown deben fijarse mirando 2022 y 2020, no únicamente el promedio.

10 Comparativa frente a benchmarks

Se construyen dos benchmarks de referencia: (1) cartera 60/40 estática usando $0.6 \cdot IWDA + 0.4 \cdot IEAG$, considerada el "mínimo competitivo" para una cartera diversificada; (2) SPY como proxy de RV americana de referencia.

Criterio de éxito M4 (heredado de Fase 0)

La cartera moderada construida en M4 deberá presentar un Sharpe ratio histórico (en backtest fuera de muestra) **igual o superior** al del benchmark 60/40 sobre el mismo período. De lo contrario, el motor de optimización no aporta valor frente a una asignación naive.

11 Decisiones metodológicas — síntesis

Se recopilan en una única tabla las decisiones tomadas durante el EDA, su motivación y su impacto previsible en fases posteriores. Esta tabla es la principal aportación documental de la memoria para garantizar trazabilidad.

#	Decisión	Motivación	Impacto en fases siguientes
D1	Período: 2010-09-06 → 2026-04-24	Inicio común determinado por IHYG.L; 15.92 años cubren ZIRP, COVID y normalización post-2022.	Inputs robustos a M3.
D2	Precios ajustados (auto_adjust=True)	Métrica relevante = retorno total al inversor; ETFs de distribución requieren ajuste por dividendos.	Evita sesgo a la baja en RF y RV emergente.
D3	Forward-fill ≤ 3 días	Absorbe festivos cruzados sin enmascarar suspensiones reales.	Series alineadas en calendario común.
D4	Filtro bad-tick ± 20 % round-trip	EQQQ.DE tiene ticks erróneos en 2011. Sin filtro, σ inflada de 21 % a 39 %.	σ y ρ realistas.
D5	Retornos simples (no log)	Compatibilidad directa con la formulación lineal de Markowitz.	Pesos óptimos interpretables sin transformación.
D6	Mantener IEAG y EUNH pese a $\rho = 0.91$	Cumplen funciones distintas (soberano vs. crédito IG); el optimizador puede asignar peso cero.	Universo de 9 activos preservado en M3.
D7	Sustituir IQQP.DE por INFR.AS	IQQP $\sigma = 18.5$ % (equivalente a RV emergente) no era diversificador moderado. INFR $\sigma = 13.8$ % y baja correlación con RF.	Perfil moderado correctamente representado.
D8	Conservar Ledoit-Wolf pese a $\alpha = 0.0073$	Garantiza Σ definida positiva, coste nulo, defendible académicamente.	Σ_{LW} como input estable del problema cuadrático en M3.
D9	Anualización con 252 días de mercado	Convención estándar; coherente con la literatura y proveedores.	Métricas comparables con benchmarks externos.

Tabla 6. Registro de decisiones metodológicas del EDA.

12 Veredicto Go/No-Go de Fase 1

Aplicamos los criterios definidos en la Fase 0 para decidir si se procede a M3:

#	Criterio	Resultado	Estado
1	Todos los tickers con ≥ 10 años de historia con ≥ 10 años	1592 años	✓
2	Missing post-limpieza $< 1\%$ en todos los ETFs	0% tras alineamiento	✓
3	Volatilidades coherentes con el perfil	9 de 9 ETFs encajan	✓
4	Ningún par con $\rho > 0.95$	Máximo: 0.91 (IEAG/EUNH)	✓
5	Σ_{LW} definida positiva	Verificado por Cholesky	✓
6	MDD por perfil dentro de tolerancias	Documentado y aceptado	✓
7	Outputs persistidos y reproducibles	4 ficheros generados	✓

Veredicto · GO

Se cumplen los **siete criterios** de la Fase 1. Los inputs estadísticos quedan validados y persistidos; el siguiente módulo (M3 — Optimización de carteras) puede consumirlos sin reproceso.

13 Outputs y trazabilidad para M3

El notebook deja en disco cuatro artefactos, todos en el mismo directorio que el propio notebook, listos para ser cargados desde el módulo de optimización:

Fichero	Contenido	Uso en M3
prices.parquet	Precios ajustados diarios (raw, sin recortar)	Auditoría / re-cálculo
returns.parquet	Retornos diarios alineados, post-limpieza	Backtest, HRP
mu.pkl	Vector retornos esperados anualizados (9×1)	Markowitz (objetivo)
cov_ledoit_wolf.pkl	Matriz de covarianza Ledoit-Wolf (9×9)	Markowitz (riesgo)

Reproducibilidad

El proceso completo es reproducible ejecutando el notebook end-to-end. Las dependencias son: yfinance, pandas, numpy, scikit-learn, seaborn, matplotlib. El único elemento no determinista son los precios devueltos por yfinance, que pueden variar marginalmente si Yahoo Finance corrige datos históricos retroactivamente. La estructura del pipeline y todas las decisiones documentadas en esta memoria permanecen invariantes.

Fin de la memoria