

DUDAS RESUELTAS · EDICIÓN 2026

Financial *Phrasebank* EDA

Un manual práctico sobre la estructura anidada del dataset de Malo et al. (2014), los cuatro niveles de acuerdo, y cómo evaluar modelos con clases desbalanceadas sin que la accuracy nos engañe.

14.780

FILAS EN EL CSV

4.838

FRASES ÚNICAS

3LABELS DE
SENTIMIENTO**4**NIVELES DE
CONFIANZA

Tu analista de datos favorito, listo para el EDA.

AUTOR

Juan — *Manual de Aprendizaje Personal*

REFERENCIA

Malo et al. (2014) · *Financial PhraseBank*

NAVEGACIÓN DEL MANUAL

00 Índice de contenidos

Este manual se divide en **tres bloques**: los fundamentos del dataset, las implicaciones para evaluar FinBERT, y la detección de anomalías que pueden contaminar la métrica final.

BLOQUE I · ESTRUCTURA DEL DATASET

01	¿Qué es el Financial PhraseBank?	p. 3
02	Los 4 niveles de acuerdo (thresholds)	p. 3
03	Estructura de cajas anidadas (nesting)	p. 4
04	¿Por qué una frase aparece 4 veces?	p. 4
05	Los números del dataset y el ratio de repetición	p. 5
06	¿Es un error? ¿Es intencionado?	p. 5
07	Implicaciones para el TFM	p. 6
08	Resumen · la lección clave	p. 6

BLOQUE II · EVALUACIÓN CON CLASES DESBALANCEADAS

09	Accuracy vs F1-macro en desbalance de clases	p. 7–9
10	Reportar en la memoria del TFM	p. 10

BLOQUE III · DETECCIÓN DE ANOMALÍAS

11	Feature engineering y outliers	p. 11
12	IQR · Z-score · Isolation Forest	p. 12



CÓMO LEER ESTE MANUAL Cada sección termina con una *nota clave* o *checklist* aplicable al TFM. Los bloques de código están listos para copiar y pegar en tu notebook de Fase 2.

MÓDULO M1 · FUNDAMENTOS

01 ¿Qué es el Financial PhraseBank?

El **Financial PhraseBank** es un dataset de análisis de sentimiento financiero creado por Malo et al. (2014). Contiene frases extraídas de noticias financieras en inglés, etiquetadas con tres categorías de sentimiento: **positive** **negative** **neutral**.

Lo que hace especial a este dataset es que sus frases no fueron etiquetadas por una sola persona, sino por **16 anotadores independientes** que votaron de forma simultánea. Ese diseño multi-anotador produce la llamada *estructura anidada por threshold de acuerdo*.

Un ejemplo concreto

“The company reported strong quarterly earnings.”

14 pos

1 neu

1 neg

Acuerdo: $14 / 16 = 87,5 \%$ de los anotadores coinciden en **positive**. Es una frase de *alto consenso*; entrará en los subconjuntos más estrictos.

MÓDULO M1 · FUNDAMENTOS

02 Los 4 niveles de acuerdo (thresholds)

Los autores crearon **cuatro versiones** del dataset filtrando frases según cuántos anotadores coincidían en la etiqueta mayoritaria. *A mayor exigencia, menos frases pero mayor fiabilidad.*

Threshold	Condición	Ejemplo (14/16 = 87,5%)	Frases únicas
50agree	$\geq 50 \% \rightarrow \geq 8$ de 16	✓ Sí entra	4.838
66agree	$\geq 66 \% \rightarrow \geq 11$ de 16	✓ Sí entra	2.815
75agree	$\geq 75 \% \rightarrow \geq 12$ de 16	✓ Sí entra	1.189
AllAgree	100 % $\rightarrow$ 16 de 16	✗ NO entra	2.259

NOTA La frase del ejemplo entra en 50agree, 66agree y 75agree, pero **no** en AllAgree porque falta 1 voto para el 100 %.

MÓDULO M1 · FUNDAMENTOS

03 Estructura de cajas anidadas

Los subconjuntos son **anidados**: cada nivel más estricto es un subconjunto propio del anterior. Se puede imaginar como cajas que se encierran unas dentro de otras, desde la más permisiva (exterior) hasta el *gold standard* (núcleo).



Figura 1 — Representación visual de la estructura anidada por threshold.

La analogía médica

Threshold	Analogía médica	Nivel de certeza
50agree	Diagnóstico por 1 médico de 2	Baja
66agree	Diagnóstico por 2 médicos de 3	Media
75agree	Diagnóstico por 3 médicos de 4	Alta
AllAgree	Todos los médicos coinciden	Máxima

MÓDULO M1 · ESTRUCTURA DEL CSV

04 ¿Por qué una frase aparece 4 veces?

Al concatenar los 4 archivos en un único CSV, la misma frase queda repetida hasta 4 veces. Cada fila representa: “esta frase pertenece al subconjunto de confianza X”.

id	sentence	label	agreement_level
Manual · NLP / Data Science			Malo et al. (2014) — JASIST
1	“The company reported strong...”	positive	50agree


MÓDULO M1 · ESTRUCTURA DEL CSV

05 Los números del dataset y el ratio de repetición

Al analizar el CSV concatenado se obtienen estos números clave:

Métrica	Valor	Interpretación
Total filas en el CSV	14.780	Incluyendo todas las repeticiones
Frases únicas	4.838	Sin contar duplicados por threshold
Ratio de repetición	≈ 3,05 x	$14.780 \div 4.838 \rightarrow$ cada frase aparece ~3 veces
% de filas duplicadas	~67 %	De las 14.780 filas, ~9.942 son repeticiones

Distribución visual del CSV



CLAVE ¿Por qué **~3,05** y no exactamente 4? Porque no todas las frases están en los 4 niveles. Las más ambiguas solo entran en **50agree** ; las claras aparecen en los cuatro. El promedio resulta en **~3 repeticiones**.

MÓDULO M1 · DISEÑO DEL DATASET

06 ¿Es un error? ¿Es intencionado?

RESPUESTA NO es un error. Los autores diseñaron esta estructura deliberadamente para que cada investigador elija el nivel de confianza que necesita para su caso de uso.

Los 3 motivos del diseño anidado

01 · DIFERENTES USUARIOS

Un investigador puede priorizar **volumen** ($\rightarrow$ 50agree) o

fiabilidad **máxima** ($\rightarrow$ AllAgree).

Martí, NLP / Data Science

02 · PRACTICIDAD

Es más cómodo publicar **una sola tabla anidada** que cuatro archivos separados.

03 · REPRODUCIBILIDAD

Al incluir todos los niveles se pueden reportar resultados en **múltiples thresholds** y verificar robustez.

Malo et al. (2014) — JASIST

MÓDULO M1 · IMPLICACIONES

07 Implicaciones para el TFM

Entender la estructura anidada tiene implicaciones directas sobre **cómo diseñar experimentos** y **cómo reportar resultados**:

Decisión	Acción recomendada	Motivo
Accuracy principal	Usar <code>allagree</code>	2.259 frases con 100 % de consenso = resultado más creíble
Análisis de robustez	Complementar con <code>≥75agree</code>	3.448 frases: verificar que las conclusiones se mantienen
No usar como métrica principal	NO usar <code>50agree</code>	Alto ruido: decisiones borderline contaminan la conclusión
Filtrado del CSV	<code>df[df.agreement == "allagree"]</code>	Eliminar duplicados antes de cualquier split train/test



RECOMENDACIÓN TFM En la memoria del TFM reportarás **dos números**: accuracy en `allagree` (gold standard) y accuracy en `≥75agree` (robustez). Si ambos son similares, las conclusiones son sólidas.

MÓDULO M1 · CIERRE

08 Resumen · La lección clave

Datos anidados = la misma entidad en múltiples niveles de fiabilidad. El CSV mezcla los cuatro grupos; el investigador decide cuál usar.

50agree**4.838**

Máx. volumen · mín. confianza

66agree**2.815**

Balance volumen / confianza

75agree**1.189**

Alta confianza · validación

AllAgree**2.259**

Gold Standard · máx. fiabilidad

Referencia: Malo, P., Sinha, A., Korhonen, P., Wallenius, J., & Takala, P. (2014). Good debt or bad debt: Detecting semantic orientations in economic texts. JASIST.

MÓDULO M1 · EVALUACIÓN

09 Accuracy vs F1-macro en desbalance

Una vez elegido el subconjunto correcto del dataset, surge la segunda gran decisión: **¿qué métrica usamos para evaluar el modelo?** Con clases desbalanceadas, la accuracy sola puede engañarnos de forma grave.

El problema · distribución de clases

El Financial PhraseBank (`allagree`) presenta un notable desbalance entre clases. La clase **neutral** domina ampliamente, mientras que **positive** es minoría.

60 % neutral	28 % negative	12 % positive
-----------------	------------------	------------------

Distribución de clases en el subconjunto `allagree` .

Clase	% del total	Relevancia
neutral	60 %	Mayoría abrumadora. Fácil de predecir.
negative	28 %	Crítica en finanzas (riesgo, pérdida).
positive	12 %	Minoría. La más difícil de detectar.

El truco peligroso de la accuracy

Imagina un modelo que comete un error estúpido pero "astuto": "voy a predecir SIEMPRE neutral para todo". ¿Qué pasa?

Clase real	Predicción	¿Correcto?
neutral	neutral	✓ Acierto
neutral	neutral	✓ Acierto
neutral	neutral	✓ Acierto
neutral	neutral	✓ Acierto
neutral	neutral	✓ Acierto
neutral	neutral	✓ Acierto
negative	neutral	✗ Fallo grave
positive	neutral	✗ Fallo



PROBLEMA Accuracy = $6 / 8 = 75\%$ — ¡pero el modelo *nunca* detecta **negative** ni **positive**!

MÓDULO M1 · CASO DE USO

¿Por qué la clase *negative* es la más crítica?

En un contexto de **roboadvisors financieros**, predecir incorrectamente el sentimiento **negative** tiene consecuencias reales para los clientes:

ESCENARIO 1 · FINBERT ACIERTA

Predice **negative**

- El roboadvisor clasifica al cliente como **conservador**.
- Cartera de bajo riesgo (bonos, monetario).
- Cliente durmiendo tranquilo.

ESCENARIO 2 · FINBERT FALLA

Predice **neutral** / **positive**

- Clasifica al cliente como **moderado / agresivo**.
- Cartera de alto riesgo (acciones, emergentes).
- El cliente **pierde más dinero** → problema legal.

LECCIÓN El falso negativo (no detectar miedo / aversión al riesgo) es **mucho más costoso** que el falso positivo (sobreestimar la cautela). Es el *"canario en la mina"* del sistema.

Matriz de confusión · el panorama completo

Con desbalance 60/28/12, una matriz de confusión típica de FinBERT revela el problema real que la accuracy global ocultaba:

REAL	— Predicción —			
	negative	neutral	positive	negative
95	45	10	neutral	5
280	15	positive	0	35
15				

Figura 2 — Matriz de confusión con desbalance 60/28/12. Verde = aciertos · rojo = errores.

Clase	Aciertos	Total	Accuracy de clase
negative	95	150	63 % · margen de mejora
neutral	280	300	93 % · excelente
positive	15	50	30 % · pobre
Global	390	500	78 %

MÓDULO M1 · EVALUACIÓN

Aquí llega el F1-macro

El **F1-macro** da el *mismo peso a cada clase*, sin importar cuán frecuente sea. Promedia el F1-score de cada clase individualmente:

Fórmulas clave

$F1_{clase} = 2 \times (\text{Precisión} \times \text{Recall}) / (\text{Precisión} + \text{Recall})$

$F1\text{-macro} = (F1_{negative} + F1_{neutral} + F1_{positive}) / 3$

Calculado sobre el ejemplo anterior (500 frases)

Clase	Precision	Recall	F1-score	Interpretación
negative	0.90	0.63	0.72	Aceptable, margen de mejora
neutral	0.83	0.93	0.93	Excelente — clase dominante
positive	0.50	0.30	0.30	Pobre — minoría infrarrepresentada
F1-MACRO	—	—	0.65	$(0.72 + 0.93 + 0.30) / 3$ · 13 pp por debajo de la accuracy

Accuracy vs F1-macro · la brecha que importa

Accuracy global



78 %

Engañosa con desbalance

F1-macro



65 %

Revela la verdad



LECTURA Accuracy global: **78 %** ← te miente (parece bien gracias a *neutral*). F1-macro: **65 %** ← revela la verdad (*negative* y *positive* son débiles).

Analogía · detector de enfermedades raras

El problema es idéntico al de un clasificador médico que evalúa pacientes mayoritariamente sanos:

Escenario	Accuracy	F1-macro	Realidad
Modelo predice “sano” para todos	95 %	20 %	Parece bueno, pero NO detecta enfermos
Modelo equilibrado (F1 balanceado)	85 %	80 %	Realmente bueno en todas las clases

MÓDULO M1 · ENTREGA

¿Cómo reportar bien en la memoria del TFM?

X INCORRECTO

"El modelo logró 85 % de accuracy, superando el objetivo de 85 %."

✓ CORRECTO

"El modelo logró 85 % de accuracy y 74,8 % de F1-macro. Aunque cumple la métrica contractual, la accuracy en la clase **negative** (68 %) es insuficiente. Esto refleja el desbalance 60/28/12 del dataset. Se recomienda usar F1-macro como métrica primaria en futuras iteraciones."

Checklist de código · Fase 2 (M1)

Cuando implementes FinBERT, usa estas **tres métricas conjuntas** para un diagnóstico completo:

```
from sklearn.metrics import accuracy_score, f1_score, classification_report

# Sobre financial_phrasebank_allagree
y_true = df_allagree["label"]
y_pred = finbert_predictions

# Métrica 1 · Accuracy global (contractual)
accuracy = accuracy_score(y_true, y_pred)
print(f"Accuracy: {accuracy:.1%}")

# Métrica 2 · F1-macro (equidad por clase)
f1_macro = f1_score(y_true, y_pred, average="macro")
print(f"F1-macro: {f1_macro:.1%}")

# Métrica 3 · Informe completo (diagnóstico por clase)
print(classification_report(y_true, y_pred))
# ↑ muestra precision, recall, F1 por cada clase
```

Salida esperada en el TFM

— Módulo M1 · Resultados en Financial PhraseBank (allagree) —

Accuracy global : 85.2 % ← métrica contractual (Fase 0)
F1-macro : 74.8 % ← métrica de equidad por clase

Accuracy por clase:

negative : 68 % ← ★ LA MÁS IMPORTANTE
neutral : 92 % ← fácil (mayoría)
positive : 48 % ← difícil (minoría)

Accuracy por clase · visualización

Manual · NLP / Data Science

sklearn.metrics · Juan · Manual de Aprendizaje Personal

negative

68 %

neutral

92 %

MÓDULO M1 · CALIDAD DE DATOS

11 Detección de anomalías · feature engineering

La pregunta fundamental de esta sección es: *¿hay frases que sean “raras” o “anormales” en el dataset?* Si las hay, podrían introducir **data quality issues** que contaminen la evaluación de FinBERT.

Ejemplos de frases sospechosas

X DEMASIADO LARGAS

Una frase con 10.000 caracteres (texto completo de un informe).

X SOLO NÚMEROS

“123 456 789 000” — no es una frase, es una serie.

X 95 % MAYÚSCULAS

“APPLE STOCK SOARS!!!!!!!!!!” — estilo clickbait / spam.

✓ FRASE VÁLIDA

“Apple Inc. reports strong quarterly earnings.”

Parte 1 · Las 4 características que extraemos

Creamos cuatro columnas nuevas para *cada frase*, que describen su perfil tipográfico:

```
df_unique = df_unique.assign(
    n_digits = df_unique['sentence'].str.count(r'\d'),      # contar dígitos
    n_upper  = df_unique['sentence'].str.count(r'[A-Z]'),    # contar mayúsculas
).assign(
    ratio_digits = lambda d: d['n_digits'] / d['len_chars'], # % dígitos
    ratio_upper  = lambda d: d['n_upper'] / d['len_chars'],  # % mayúsculas
)
```

Característica	Fórmula	Interpretación
len_chars	count(caracteres)	Tamaño bruto de la frase
len_words	count(palabras)	Longitud estructural
n_digits	count(/d/)	Número de dígitos presentes
n_upper	count(/[A-Z]/)	Número de mayúsculas
ratio_digits	n_digits / len_chars	Densidad numérica
ratio_upper	n_upper / len_chars	Densidad de mayúsculas

Ejemplo concreto · frase normal vs frase spam

MÓDULO M1 · CALIDAD DE DATOS

12 Tres métodos para detectar outliers

Con las 4 características ya calculadas, buscamos frases cuyos valores estén **fuera de lo normal**. Existen tres estrategias complementarias:

Método 1 · IQR (regla de Tukey)

```
def outliers_iqr(s: pd.Series, k: float = 1.5) → pd.Series:
    q1, q3 = s.quantile([0.25, 0.75]) # cuartiles
    iqr = q3 - q1                      # rango intercuartílico
    return (s < q1 - k * iqr) | (s > q3 + k * iqr)
```

Ejemplo con `len_words`: si $Q1=10$ y $Q3=22$, entonces $IQR=12$. El umbral superior es $Q3 + 1.5 \times IQR = 40$. **Cualquier frase con más de 40 palabras queda marcada como outlier.**

Método 2 · Z-score

```
def outliers_zscore(s: pd.Series, z: float = 3.0) → pd.Series:
    return np.abs((s - s.mean()) / s.std()) > z
```

Si $|z| > 3$, el valor está a 3 desviaciones estándar de la media — ocurre en **< 0,3 %** de los casos en una distribución normal. Ejemplo: con $\mu = 15$ y $\sigma = 5$, una frase de 50 palabras da $z = 7 \rightarrow$ outlier.

Método 3 · Isolation Forest

```
X = StandardScaler().fit_transform(df_unique[features])
iso = IsolationForest(contamination='auto')
iso_mask = iso.fit_predict(X) == -1
```

Intenta *aislar* cada punto en el espacio. Si una frase es fácil de aislar (rodeada de vacío), es un outlier. **Funciona en múltiples dimensiones simultáneamente** y no asume distribución normal.

Comparativa de los tres métodos

Método	Nº outliers	%	Característica
IQR (<code>len_words</code>)	45	0,93 %	Univariante, robusto a outliers previos
Z-score > 3 (<code>len_words</code>)	18	0,37 %	Univariante, asume normalidad
Manual · NLP / Data Science IsolationForest (4 feats)	72	1,49 %	Multivariante, detecta combinaciones

CIERRE DEL MANUAL

Tres números, una conclusión sólida.

Elige el subconjunto correcto del dataset. Reporta **accuracy**, **F1-macro** y **accuracy sin outliers**. Vigila siempre la clase *negative*. Si esos gestos son coherentes, tu evaluación es defendible.

Dataset**Usa allagree**

2.259 frases con 100 % de consenso para la métrica principal.

Métrica**Accuracy + F1-macro**

Dos cifras conjuntas revelan el desbalance que la accuracy oculta.

Calidad**Marca outliers**

IsolationForest sobre 4 features — reporta accuracy con y sin ellos.

“Outliers ≠ datos malos. Outliers = datos inusuales que merecen inspección.”